

# Machine Learning Fundamentals

Hari 1 · Navasena Gen-ML Course · Batch 6

---

10 notebook · Python · Google Colab

Navasena AI

# Peta hari ini

## Regresi

nb01 Linear Regression

## Klasifikasi

nb02 Logistic Regression  
nb03 Decision Tree  
nb04 KNN  
nb05 SVM

## Ensemble

nb06 Voting, bagging, boosting  
nb07 XGBoost

## Clustering

nb08 K-Means, hierarchical, DBSCAN

## Time series

nb09 Dekomposisi dan SARIMA

## GPU

nb10 cuML dan XGBoost di GPU

Sebelum notebook pertama kita bahas alur kerjanya dulu: bagaimana model belajar, dan bagaimana hasilnya diuji.

Act 1

# Apa itu Machine Learning?

*Kalau aturannya tidak bisa ditulis, biarkan datanya yang bicara*

---

### Spam filter versi if/else

- Subjek memuat “GRATIS” → dikirim sebagai “G R A T I S”
- Pengirim tidak dikenal → alamat baru dibuat tiap hari
- Lima tanda seru → dikurangi jadi dua


### Versi machine learning

- 10.000 email yang sudah ditandai spam atau bukan
- Model menyesuaikan parameternya untuk menangkap pola pada contoh itu
- Contoh baru masuk, polanya ikut diperbarui

### Intinya

Machine learning adalah program yang aturannya dipelajari dari contoh, bukan ditulis tangan satu per satu.

# Tiga jenis machine learning



- **Supervised**: setiap contoh punya jawabannya. Sembilan notebook pertama ada di sini.
- **Unsupervised**: tanpa jawaban, model mencari struktur dalam data. Ini clustering di nbo8.
- **Reinforcement**: belajar dari reward atas tindakannya. Hari ini hanya sebagai konteks.

## Contoh yang kamu pakai tiap hari

| Layanan     | Yang diprediksi               | Jenis tugas |
|-------------|-------------------------------|-------------|
| Gmail       | email ini spam atau bukan     | klasifikasi |
| Google Maps | lama waktu tempuh             | regresi     |
| Spotify     | pendengar dengan selera mirip | clustering  |
| Toko online | permintaan minggu depan       | time series |

Keempat baris ini memakai kelompok model yang kita buka hari ini juga. Bedanya ada di ukuran data dan jumlah orang yang merawat sistemnya.

## Tools hari ini

- **Python** — bahasa yang dipakai sepanjang hari
- **Google Colab (GPU T4)** — menjalankan notebook tanpa instalasi di laptop
- **pandas, matplotlib** — memuat data, melihat isinya, membuat grafik
- **scikit-learn** — hampir semua model klasik di modul ini
- **XGBoost** — boosting untuk data tabular (nb07)
- **cuML** — model klasik yang dijalankan di GPU (nb10)

Semua notebook memuat datanya langsung dari URL, jadi tidak ada file yang perlu kamu unggah dulu.

## Act 2

# Bagaimana model belajar dan diuji?

*Dari kolom data mentah sampai satu angka yang layak dilaporkan*

---



## Feature dan target

| TV    | radio | newspaper | sales |
|-------|-------|-----------|-------|
| 230,1 | 37,8  | 69,2      | 22,1  |
| 44,5  | 39,3  | 45,1      | 10,4  |
| 17,2  | 45,9  | 69,3      | 9,3   |

tiga feature                      target

- **Feature** adalah kolom masukan yang dipakai model: belanja iklan di tiga kanal.
- **Target** adalah nilai yang mau diprediksi: penjualan.
- Targetnya berupa angka, jadi tugasnya regresi. Kalau targetnya kategori, itu klasifikasi dan targetnya disebut label kelas.

### Soal latihan

- Dikerjakan berulang sampai polanya kelihatan
- Jawabannya sudah ada di buku

### Soal ujian

- Belum pernah dilihat sebelumnya
- Nilainya baru berarti kalau soalnya memang baru

### Intinya

Data train dipakai untuk melatih model. Data test disimpan utuh dan dipakai sekali di akhir untuk menilai hasilnya.


## Data train, validation, dan test




- Proporsinya bukan aturan baku; 60/20/20 dan 80/20 sama-sama umum.
- Kalau datanya sedikit, validation diganti cross-validation di data train.

- Tujuannya memprediksi respons nasabah sebelum telepon dilakukan.
- Kolom `duration` baru lengkap setelah panggilan berakhir.
- Memakai kolom itu membuat hasil evaluasi terlalu optimistis.


Ini salah satu bentuk leakage. Bentuk lain kita bahas di nbo2.



# Scaling: menyamakan rentang antar feature



- Nilai gaji ada di puluhan ribu, umur di puluhan tahun. Tanpa scaling, selisih gaji mendominasi perhitungan jarak.
- Model berbasis jarak (KNN, SVM) dan model dengan penalti koefisien (logistic regression) butuh scaling; decision tree dan random forest tidak.



- Garis hijau adalah prediksi model, titik hijau muda adalah data sebenarnya.
- Garis putus-putus oranye adalah error prediksi tiap baris.
- Melatih model berarti mengubah parameternya sampai total error itu sekecil mungkin.


## Loss: satu angka yang diminimalkan

### Mean Squared Error

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- $y_i$  nilai sebenarnya,  $\hat{y}_i$  prediksi model,  $n$  jumlah baris.
- Selisihnya dikuadratkan, jadi error besar menyumbang jauh lebih banyak daripada beberapa error kecil.
- Pelatihan mencari parameter dengan MSE terkecil di data train. Angka yang dilaporkan tetap diambil dari data yang tidak dipakai melatih.


# Underfitting dan overfitting



- **Kiri:** garis lurus terlalu sederhana untuk pola yang melengkung. Error di data train dan data test dua-duanya besar.
- **Tengah:** masih mengikuti pola utama tanpa melewati semua titik.
- **Kanan:** mengikuti hampir setiap titik, termasuk variasi acaknya. Error train turun, error test naik.



## Bias–variance trade-off



- Model yang terlalu sederhana dapat melewati pola.
- Model yang terlalu peka terhadap data train dapat berubah banyak ketika sampel pelatihannya berubah.
- Error di data train hampir selalu turun saat model dibuat lebih rumit. Yang perlu dilihat adalah error di data yang tidak dipakai melatih.

## Cross-validation: menilai model lima kali

data train dibagi lima bagian sama besar



- Tiap putaran, satu bagian (oranye) dipakai menilai, empat sisanya untuk melatih.
- Skornya rata-rata lima putaran, jadi tidak bergantung pada satu potongan data yang kebetulan mudah.
- Data test tetap di luar semua ini.

## Baseline: pembandingan paling sederhana

- **Regresi:** prediksi satu nilai konstan, yaitu rata-rata target di data train.
- **Klasifikasi:** prediksi kelas mayoritas untuk semua baris.
- Di `income_evaluation.csv`, 76% baris berlabel  $\leq 50K$ . Model yang memprediksi kelas itu untuk semua baris sudah dapat akurasi 76%.

**Jebakan:** akurasi 76% pada data seperti itu belum menunjukkan apa pun. Hitung baseline lebih dulu, lalu lihat selisih hasil modelmu terhadap baseline.

## Metrik regresi: MAE, RMSE, $R^2$

| Metrik | Arti                                                                                                                                                              |
|--------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| MAE    | rata-rata selisih absolut prediksi dan nilai sebenarnya; satuannya sama dengan target                                                                             |
| RMSE   | akar dari rata-rata kuadrat error; lebih peka terhadap error besar daripada MAE karena perhitungannya memakai kuadrat error                                       |
| $R^2$  | membandingkan error kuadrat model dengan prediksi konstan berupa rata-rata target; 1 berarti prediksi tepat, 0 setara pembanding itu, negatif berarti lebih buruk |

Pilih metrik sebelum melatih model, bukan setelah melihat hasilnya.

## Confusion matrix: dua jenis kesalahan


Positif berarti kondisi yang ingin dideteksi, bukan hasil yang baik.

|      |       | Prediksi: Tidak                         | Prediksi: Ya                         |
|------|-------|-----------------------------------------|--------------------------------------|
| Asli | Tidak | <b>True Negative</b>                    | <b>False Positive</b><br>alarm palsu |
|      | Ya    | <b>False Negative</b><br>kasus terlewat | <b>True Positive</b>                 |

Akurasi menjumlahkan dua kotak hijau saja. Dua kotak sisanya punya biaya yang berbeda, dan itu yang menentukan metrik mana yang kita pakai.

# Precision, recall, F1, dan ROC-AUC

- **Precision:** dari yang diprediksi positif, berapa bagian yang benar positif.
- **Recall:** dari yang benar-benar positif, berapa bagian yang tertangkap.
- **F1:** rata-rata harmonik precision dan recall, turun tajam kalau salah satu rendah.
- **ROC-AUC:** peluang model memberi skor lebih tinggi pada satu contoh positif dibanding satu contoh negatif.



Model logistic regression pada data banking tanpa duration.

## Alur kerja yang dipakai di sepuluh notebook

1. Definisikan masalahnya dan metrik yang akan dilaporkan.
2. Siapkan data: periksa nilai kosong, outlier (pencilan), dan kolom yang tidak tersedia saat prediksi.
3. Split data train, validation, dan test.
4. Latih model di data train.
5. Bandingkan hasilnya dengan baseline.
6. Tuning hyperparameter dengan cross-validation di data train.
7. Uji sekali di data test, lalu laporkan angka itu.

Langkah 2 dan 3 memakan waktu paling banyak. Langkah 7 yang paling sering dilewati.