

Machine Learning Fundamentals

Navasena Gen-ML Course

Navasena

Act 1

Apa itu Machine Learning?

Bagaimana komputer bisa belajar dari data?

Apa itu Machine Learning?

Konsep Dasar

- Komputer belajar **pola** dari data
- Tanpa diprogram secara **eksplisit**
- Makin banyak data → **makin pintar**

Definisi:

ML adalah bidang AI di mana sistem belajar dari pengalaman tanpa instruksi eksplisit untuk setiap kasus.


Contoh Nyata Sehari-hari

- **Spotify** tahu lagu kesukaanmu
- **Gmail** tahu mana yang spam
- **Google Maps** prediksi waktu tempuh


Kunci:

Semua layanan ini menggunakan pola dari data historis jutaan pengguna.

Tiga Jenis Machine Learning



Peta Perjalanan Modul 1



■ Supervised ■ Unsupervised ■ Forecasting ■ GPU Acceleration

Tools yang Kita Gunakan

Python

Bahasa pemrograman utama

Google Colab

Notebook di cloud dengan GPU gratis

scikit-learn

Library ML #1

NVIDIA GPU


Akselerasi 10–50x lebih cepat

Act 2

Menebak Angka

Bagaimana memprediksi sebuah nilai?

Linear Regression — Garis Terbaik



- Mencari garis yang paling pas

⇒ Formula: $y = w \cdot x + b$

- **w** = kemiringan (seberapa besar pengaruh)

- **b** = titik awal


Seperti menebak harga es krim berdasarkan suhu hari ini

Seberapa Bagus Prediksi Kita?

Metrik	Arti	Nilai Ideal
MAE	Rata-rata kesalahan	$\rightarrow 0$
RMSE	Kesalahan (penalti besar)	$\rightarrow 0$
R^2	% data yang dijelaskan	$\rightarrow 1.0$
MAPE	Kesalahan dalam persen	$< 10\%$


Time Series — Memprediksi Masa Depan

- Data yang berurutan berdasarkan waktu



SARIMA — Menangkap Pola Musiman

Seasonal AutoRegressive Integrated Moving Average



Ringkasan: Menebak Angka

- ✓ **Linear Regression** → mencari garis terbaik untuk data
- ✓ **R^2 Score** → seberapa bagus model (mendekati 1.0 = bagus)
- ✓ **Time Series** → data berurutan waktu, ada trend + musiman
- ✓ **SARIMA** → model yang menangkap pola musiman otomatis

Act 3

Menebak Kategori

Ya atau Tidak? Spam atau Bukan?

Klasifikasi vs Regresi


Regresi



Prediksi **angka** (kontinu)

Contoh: harga rumah, suhu

Klasifikasi



Prediksi **kategori** (diskrit)

Contoh: spam/bukan, lulus/tidak

Logistic Regression — Probabilitas Ya/Tidak




Output sigmoid selalu antara 0 dan 1 — mudah diinterpretasi sebagai probabilitas.

Confusion Matrix — Detail Kesalahan

		Prediksi: Tidak	Prediksi: Ya
Asli: Ya Asli: Tidak	Asli: Tidak	True Negative ✓	False Positive (!)
	Asli: Ya	False Negative (x)	True Positive ✓

Seperti tes COVID: FP = alarm palsu, FN = terlewat (bahaya!)

Decision Tree — Diagram Alur Keputusan




KNN — Siapa Tetanggamu?




Lihat 5 tetangga terdekat → mayoritas hijau → prediksi: **Hijau**

SVM — Margin Terlebar




Perbandingan 4 Model Klasifikasi




Dataset yang sama, hasil yang berbeda — setiap model punya ‘cara berpikir’ sendiri


Overfitting vs Underfitting



Terlalu sederhana
(Underfitting)



Pas!
(Good fit)



Terlalu rumit
(Overfitting)

Kapan Pakai Model yang Mana?


Model	Batas Keputusan	Scaling?	Kecepatan	Interpretasi
Logistic Reg.	Garis lurus	Ya	Cepat	Mudah
Decision Tree	Kotak-kotak	Tidak	Cepat	Mudah
KNN	Berliku	Ya	Lambat	Sulit
SVM Linear	Garis lurus	Ya	Sedang	Sedang
SVM RBF	Melengkung	Ya	Lambat	Sulit

Act 4

Kekuatan Tim

Bagaimana jika model bekerja sama?

Voting — Ambil Suara Terbanyak



Hard Voting

Setiap model = 1 suara
Mayoritas menang

Soft Voting

Rata-rata probabilitas
Biasanya lebih akurat

Random Forest — Banyak Pohon, Satu Hutan



Satu Jawaban

500 pohon, masing-masing belajar dari data berbeda


- **Bagging** = Bootstrap Aggregating: ambil sampel data acak berulang kali
- Setiap pohon lihat data yang berbeda (*bootstrap*)
- Setiap pohon hanya boleh tanya sebagian fitur
- Hasil akhir = voting dari semua pohon
- Lebih stabil, tahan *noise*

Boosting — Belajar dari Kesalahan



Setiap model baru fokus memperbaiki kesalahan model sebelumnya

Bagging vs Boosting — Decision Boundary



Dataset yang sama, strategi berbeda — tidak ada yang selalu terbaik!

eXtreme Gradient Boosting

- *Gradient Boosting* versi super cepat
- Built-in regularisasi (anti overfitting)
- Bisa tangani data kosong otomatis
- Salah satu model paling dominan di kompetisi Kaggle

NVIDIA berkontribusi langsung pada GPU support XGBoost!

Feature Importance — Fitur Mana yang Penting?



Tidak Ada Model Terbaik untuk Semua!

Dataset *noisy* $\Rightarrow$ **Random Forest** menang

Dataset bersih $\Rightarrow$ **Gradient Boosting** menang

Dataset kecil $\Rightarrow$ **Decision Tree** cukup

Selalu coba beberapa model dan bandingkan!

No Free Lunch Theorem — setiap model punya kelebihan dan kekurangan

Ringkasan: Kekuatan Tim


- ✓ **Voting** → beberapa model berbeda, ambil suara terbanyak
- ✓ **Bagging (RF)** → banyak pohon, masing-masing data berbeda
- ✓ **Boosting** → model berurutan, perbaiki kesalahan
- ✓ **XGBoost** → juara Kaggle, didukung NVIDIA GPU
- ✓ Selalu bandingkan beberapa model!

Act 5

Menemukan Pola Tersembunyi

Bagaimana jika tidak ada jawaban benar?

K-Means Clustering



Mengelompokkan data TANPA label

1. Pilih K titik pusat acak
2. Assign data ke pusat terdekat
3. Pindahkan pusat ke rata-rata
4. Ulangi sampai stabil


Seperti menaruh magnet di meja penuh paku — paku menempel ke magnet terdekat

Berapa Jumlah Cluster yang Tepat?

Elbow Method




Silhouette Score




Metode Clustering Lain

Hierarchical Clustering



- Gabungkan cluster terdekat satu per satu
- Tidak perlu tentukan K di awal

DBSCAN



- Berdasarkan kepadatan (density)
- Bisa deteksi outlier (data aneh)
- Tidak perlu tentukan K

Ringkasan: Pola Tersembunyi

Metode	Perlu K?	Bentuk Cluster	Deteksi Outlier?
K-Means	Ya	Bulat	Tidak
Hierarchical	Opsional	Fleksibel	Tidak
DBSCAN	Tidak	Bebas	Ya

Aplikasi: segmentasi pelanggan, pengelompokan berita, rekomendasi musik

Act 6

Turbo Mode: NVIDIA GPU

Bagaimana jika bisa 50x lebih cepat?

CPU vs GPU — Apa Bedanya?

CPU

4–16 core
sangat kuat
per core

1 koki master

GPU



1.000 koki sederhana

ML = ribuan operasi matematika yang SAMA

→ cocok untuk GPU!

NVIDIA RAPIDS cuML

- Library ML di GPU dengan **API identik scikit-learn**
- Rata-rata **10–50x lebih cepat**
- 50+ algoritma: regresi, klasifikasi, clustering, PCA, ...

Ganti import, sisanya SAMA!

Perbandingan Kode: sklearn vs cuML

scikit-learn (CPU)

```
1 from sklearn.ensemble import  
  \  
2   RandomForestClassifier  
3  
4 model =  
   RandomForestClassifier()  
5 model.fit(X_train, y_train)  
6 pred = model.predict(X_test)
```

cuML (GPU NVIDIA)

```
1 from cuml.ensemble import \  
2   RandomForestClassifier  
3  
4 model =  
   RandomForestClassifier()  
5 model.fit(X_train, y_train)  
6 pred = model.predict(X_test)
```

Hanya ganti 1 baris import → 10-50x lebih cepat!

XGBoost GPU — Satu Baris Perubahan

```
1 # CPU
2 XGBClassifier(device="cpu")
3
4 # GPU NVIDIA
5 XGBClassifier(device="cuda") # Hanya ini yang berubah!
```

Perubahan kode: HANYA ganti device — sisanya 100% identik!

Benchmark: CPU vs GPU



Dari Training ke Deployment



ONNX = format standar (seperti PDF untuk dokumen)

Di server produksi: **NVIDIA Triton Inference Server**

Ekosistem NVIDIA untuk AI


Produk	Fungsi
RAPIDS cuML	ML klasik di GPU
cuDF	Pandas di GPU
XGBoost GPU	Gradient Boosting di GPU
TensorRT	Optimasi inferensi DL
NeMo	Framework NLP/AI
Triton Server	Deploy model di produksi

Kita akan pelajari lebih dalam di Modul 6!

Modul 1 — Selesai!

#	Topik	Jenis
1	Linear Regression	Supervised – Regresi
2	Logistic Regression	Supervised – Klasifikasi
3	Decision Tree	Supervised – Klasifikasi
4	KNN	Supervised – Klasifikasi
5	SVM	Supervised – Klasifikasi
6	Ensemble Methods	Supervised – Ensemble
7	XGBoost	Supervised – Ensemble
8	Clustering	Unsupervised
9	Time Series	Forecasting
10	NVIDIA GPU	Akselerasi

Apa Selanjutnya?



Terima Kasih!

Navasena Gen-ML Course
