

Deep Learning Fundamentals

Hari 2 · Navasena Gen-ML Course · Batch 6

6 notebook · TensorFlow dan Keras · Google Colab

Navasena AI

Peta hari 2

Dasar belajar

nbo1 Neural network pertama (Fashion-MNIST)

Aktivasi

nbo2 Fungsi aktivasi dan optimizer

Gambar

nbo3 CNN dan transfer learning (CIFAR-10)

Urutan

nbo4 RNN dan LSTM

GPU

nbo5 Mixed precision, ONNX, TensorRT

Generatif

nbo6 Autoencoder, GAN, diffusion

Dua act pertama membahas cara satu neural network belajar. Sisanya memakai dasar itu untuk gambar, urutan, GPU, dan model generatif.

Dari hari 1 ke hari 2

ML klasik (hari 1)

- Feature dipilih dan dirancang manusia: kolom umur, gaji, durasi
- Data tabular, satu baris satu contoh
- Modelnya kecil, koefisiennya bisa dibaca satu per satu

Deep learning (hari 2)

- Feature dipelajari dari data mentah: pixel, urutan kata
- Gambar, teks, dan sinyal berurutan
- Modelnya berlapis, jumlah parameternya ratusan ribu ke atas


Yang tidak berubah

Alur kerjanya sama seperti hari 1: pisahkan data train, validation, dan test; bandingkan dengan baseline; pilih model di data validation. Yang berubah adalah bentuk modelnya dan dari mana featurenya datang.

Act 1

Bagaimana neural network belajar?


Satu angka kesalahan, lalu diperbaiki sedikit demi sedikit



Intinya

Bobot adalah takaran: seberapa besar tiap masukan ikut dihitung. Bias menggeser hasilnya. Aktivasi menentukan bentuk keluaran neuron.

Dari satu neuron ke satu arsitektur



- Flatten menggelar gambar 28×28 menjadi satu baris berisi 784 angka.
- Dua hidden layer menyusun feature: layer berikutnya bekerja di atas keluaran layer sebelumnya.
- Output layer punya 10 neuron, satu untuk tiap kategori pakaian.

Yang berubah saat model belajar

Layer	Bobot	Bias	Parameter
Dense 128 (ReLU)	784×128	128	100.480
Dense 64 (ReLU)	128×64	64	8.256
Dense 10 (softmax)	64×10	10	650
Total			109.386

- Seratus ribu angka ini dimulai dari nilai acak, lalu diperbaiki selama training.
- Jumlah layer, jumlah neuron, dan learning rate kamu tentukan sebelum training; ketiganya bukan hasil training.


Loss: satu angka yang mengukur seberapa salah

$$\text{loss satu contoh} = -\log(p_{\text{kelas benar}})$$

- Model mengeluarkan satu probabilitas untuk tiap kelas. Loss hanya melihat probabilitas yang diberikan ke kelas yang benar.
- Probabilitas 0,85 untuk kelas yang benar memberi loss kecil; 0,05 memberi loss besar.
- Loss seluruh batch adalah rata-rata loss tiap contohnya. Angka inilah yang diperkecil saat training.

Namanya di Keras: `sparse_categorical_crossentropy`. Accuracy dilaporkan untuk kita baca; loss yang dipakai model untuk memperbaiki diri.

Gradient Descent pada $f(w) = (w-3)^2 + 1$



Intinya

Bentuk seluruh bukitnya tidak diketahui. Yang bisa diukur hanya kemiringan di titik sekarang; satu langkah diambil ke arah menurun, lalu diulang sampai kemiringannya mendekati nol.

Ketiga panel: fungsi sama, ukuran langkah berbeda.

Learning rate: ukuran langkah dan gejalanya

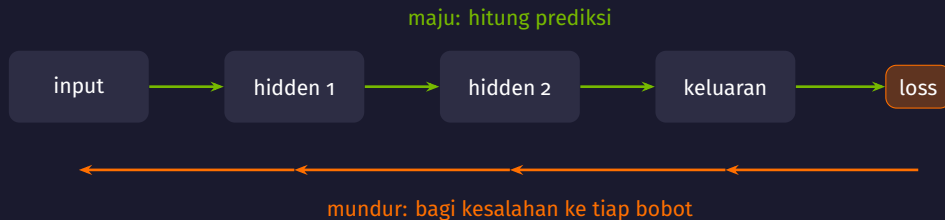
Terlalu kecil

- Loss turun, tetapi sangat lambat
- Panel kiri: 12 langkah belum sampai ke dasar
- Epoch habis sebelum modelnya selesai belajar

Terlalu besar

- Langkahnya melewati dasar, lalu menjauh
- Panel kanan: nilai w makin jauh tiap langkah
- Loss naik-turun tanpa arah, atau menjadi NaN


Jebakan: Adam memakai learning rate 0,001 sebagai nilai default. Itu titik awal yang wajar, bukan angka yang cocok untuk semua data. Kalau loss diam saja atau meledak sejak epoch pertama, ubah dulu learning ratenya sebelum menambah layer.



Intinya

Setelah loss dihitung di keluaran, tiap bobot menerima satu angka: seberapa besar sumbangannya terhadap kesalahan itu. Bobot yang menyumbang lebih banyak digeser lebih jauh.

Epoch, batch, dan satu langkah perbaikan




- Satu batch berisi 32 gambar yang dihitung bersama. Bobot diperbarui sekali untuk setiap batch.
- Satu epoch berarti seluruh data train dilewati sekali: 55.000 gambar dibagi 32 memberi 1.718 langkah perbaikan.
- Batch lebih besar membuat arah langkahnya lebih tenang, tetapi butuh memori lebih besar dan langkahnya lebih sedikit per epoch.

Angka ini dari nbo1: 55.000 data train, 5.000 validation, 10.000 test.

Kurva train dan validation dibaca berdampingan


Kurva pelatihan: Dense(128) pada Fashion-MNIST (8 epoch)



- Kedua kurva loss masih turun bersama, dan akurasi validation berhenti di sekitar 0,88.
- Kalau loss validation mulai naik sementara loss train terus turun, model mulai menghafal data train.
- Pada run ini val_loss terendah jatuh di epoch terakhir, jadi 8 epoch belum cukup untuk melihat titikbaliknya.

Overfitting: melebarnya jarak train dan validation


Overfitting vs Dropout(0.5) — 6000 sampel train, 30 epoch



- Model yang sama pada 6.000 sampel train: jaraknya 0,56 tanpa dropout dan 0,18 dengan Dropout(0,5).
- Dropout mematikan sebagian neuron secara acak tiap batch; early stopping berhenti saat val_loss tidak lagi turun.


Jebakan: Dropout hanya aktif saat training. Loss validation yang lebih rendah daripada loss train bukan keajaiban: saat evaluasi, dropoutnya dimatikan.

Normalisasi input: dari 0–255 ke 0,0–1,0



- Masukan dengan rentang besar membuat gradientnya besar juga, sehingga langkah gradient descent sulit diatur dengan satu learning rate.
- Untuk pixel, pembagiya konstanta 255. Untuk data tabular, statistik scalingnya dihitung dari data train saja, lalu dipakai apa adanya ke validation dan test.

Evaluasi multi-kelas: akurasi saja belum cukup



- Akurasi test 87,4% pada model Dense(128) di gambar ini: satu run, seed 42, data test disentuh sekali.
- Diagonal berisi prediksi yang benar. Sel di luar diagonal menunjukkan kelas apa tertukar dengan apa.
- Pasangan yang paling sering tertukar dihitung dari matriksnya, dan bisa berbeda tiap kali model dilatih ulang.
- Kelas dengan bentuk khas lebih jarang tertukar daripada kelas yang potongannya mirip.

Ringkasan Act 1


- Satu neuron menghitung jumlah berbobot dari masukannya, menambah bias, lalu melewatkannya ke aktivasi. Layer adalah kumpulan neuron seperti itu.
- Loss meringkas kesalahan menjadi satu angka. Gradient descent menurunkannya dengan langkah kecil ke arah menurun, dan backprop membagi kesalahan itu ke tiap bobot.
- Learning rate menentukan ukuran langkah: terlalu kecil membuat training lambat, terlalu besar membuatnya meledak.
- Kurva train dan validation dibaca bersama. Jarak yang melebar adalah tanda overfitting, dan dropout serta early stopping menahannya.
- Untuk klasifikasi banyak kelas, confusion matrix menunjukkan kesalahan yang tidak terlihat dari angka akurasi.

Act 2

Kenapa butuh aktivasi?

Tanpa aktivasi, seratus layer sama saja dengan satu layer

Tanpa aktivasi, tumpukan layer tetap satu garis




$$w_2 (w_1 x + b_1) + b_2 = (w_2 w_1) x + (w_2 b_1 + b_2)$$

- Hasil dua layer linear bisa ditulis ulang sebagai satu layer linear, jadi menambah layer tidak menambah bentuk yang bisa dipelajari.
- nbo2 memakai model tanpa aktivasi sebagai baseline linear, lalu membandingkannya dengan model yang beraktivasi.

Empat aktivasi dan turunannya

Fungsi Aktivasi dan Turunannya



- Baris atas fungsinya, baris bawah turunannya. Turunan inilah yang dipakai backprop.
- Daerah merah menandai tempat turunannya mendekati nol; bobot di sana hampir tidak berubah.




yang sampai ke layer 1: sekitar 0,016

Intinya

Turunan sigmoid paling besar 0,25. Saat kesalahan dibagi ke belakang melewati banyak layer, angkanya dikalikan berulang dan mengecil cepat, sehingga layer paling awal hampir tidak ikut belajar.

ReLU: turunannya tetap 1 di sisi positif

ReLU




$$f(x) = \max(0, x)$$

Leaky ReLU




- ReLU meneruskan nilai positif apa adanya dan menolak yang negatif. Turunannya 1 di sisi positif, jadi kesalahan tidak menyusut saat dibagi ke belakang.
- Perhitungannya juga murah: satu perbandingan dengan nol per neuron.
- Sisi negatifnya nol. Neuron yang masukannya negatif terus berhenti diperbarui, dan keadaan itu disebut dead ReLU.
- Leaky ReLU memberi kemiringan kecil di sisi negatif, 0,1 pada gambar sebelumnya, sehingga masih ada gradient yang mengalir.

Softmax: skor mentah menjadi probabilitas



- Softmax bekerja pada seluruh output layer sekaligus: skor 2,0; 1,0; dan 0,1 menjadi 0,66; 0,24; dan 0,10, dengan total tepat 1.
- Selisih skor satu poin menjadi selisih probabilitas yang cukup besar, karena skornya lewat fungsi eksponensial dulu.
- Untuk dua kelas, satu keluaran dengan sigmoid sudah cukup. Untuk regresi, output layer dibiarkan tanpa aktivasi.



SGD

SGD + momentum

Adam

garis oval = tempat
dengan loss sama

Intinya

SGD melangkah menurut kemiringan saat itu saja. Momentum menambahkan sisa arah langkah sebelumnya, sehingga jalurnya tidak banyak berbelok. Adam menyimpan rata-rata arah dan besar gradient, lalu menyesuaikan ukuran langkah tiap parameter.

Kapan mengganti aktivasi atau optimizer default

Cocok kalau

- banyak neuron ReLU berhenti aktif, keluarannya nol terus
- loss diam sejak epoch awal padahal datanya sudah dinormalisasi
- jaringannya dalam dan layer awalnya hampir tidak berubah

Kurang cocok kalau

- lossnya belum turun karena learning ratenya belum disesuaikan
- perbandingannya belum diuji di data validation
- modelnya masih underfit dan layernya memang terlalu sedikit

Jebakan: Dead ReLU biasanya berawal dari learning rate yang terlalu besar, bukan dari ReLU itu sendiri. Kalau lossnya tidak turun, ganti learning rate-nya dulu, sebelum arsitekturnya.

Ringkasan Act 2


- Aktivasi adalah bagian yang membuat tumpukan layer bisa mempelajari pola melengkung. Tanpa aktivasi, hasil akhirnya tetap satu layer linear.
- Sigmoid dan tanh punya turunan yang mengecil di kedua ujung, sehingga kesalahan menyusut saat dibagi ke belakang melewati banyak layer.
- ReLU menjaga turunannya tetap 1 di sisi positif dan murah dihitung, jadi dipakai sebagai pilihan awal untuk hidden layer. Leaky ReLU menyisakan gradient kecil di sisi negatif.
- Softmax dipakai di output layer klasifikasi banyak kelas; sigmoid untuk dua kelas; tanpa aktivasi untuk regresi.
- Optimizer hanya mengubah cara melangkah, bukan bukitnya. Adam menjadi titik awal yang wajar, dan learning ratenya tetap perlu diperiksa.

Act 3

Bagaimana komputer melihat gambar?

Satu filter kecil yang sama, digeser ke seluruh gambar

Gambar sampai ke model sebagai tabel angka



- Satu gambar Fashion-MNIST adalah 784 angka; satu gambar CIFAR-10 adalah 3.072 angka, karena tiap pixel punya nilai merah, hijau, dan biru.
- Dense layer membaca 3.072 angka itu sebagai satu daftar panjang: pixel bertetangga dan pixel di sudut berlawananan diperlakukan sama saja.

Konvolusi: satu filter kecil digeser ke seluruh gambar

Intuisi

Konvolusi manual: filter tepi vertikal vs horizontal




Intinya

Filter tepi vertikal bereaksi kuat hanya di tempat yang punya perubahan terang-gelap ke arah samping. Filter yang sama digeser ke semua posisi, jadi jawabannya berupa peta: di mana pola itu ditemukan.

Kedua filter ini ditulis tangan; di CNN, angka di dalam filternya dipelajari dari data.

Mekanisme konvolusi: satu jumlah berbobot per posisi



$$\text{keluaran}(r, c) = \sum_{i,j} w_{ij} x_{r+i, c+j} + b$$

- Bobot filternya dibagi bersama: sembilan angka yang sama dipakai di seluruh gambar, jadi pola yang sama tetap dikenali walau posisinya berpindah.
- `Conv2D(32, (3,3))` di `nbo3` memakai $32 \times (3 \times 3 \times 3 + 1) = 896$ parameter; satu Dense layer dari 3.072 pixel ke 1.024 neuron butuh 3.145.728 bobot.

Feature map: satu peta untuk tiap filter



- Tiap filter menghasilkan satu feature map: kuning berarti filter itu bereaksi kuat di posisi tersebut.
- Delapan peta ini dari layer konvolusi pertama sebuah CNN kecil setelah satu epoch. Ada yang menyorot goresan tebal, ada yang menyorot latar, ada yang masih hampir kosong.
- Layer berikutnya bekerja di atas peta ini, bukan di atas pixel mentah, sehingga pola yang dikenalnya makin besar dan makin abstrak.

Pooling: menyusutkan peta, menyimpan yang paling kuat

1	3	2	4
5	6	1	0
2	1	7	3
0	4	2	8

feature map 4×4

ambil nilai
terbesar



6	4
4	8

keluaran 2×2

ukurannya seperempat,
tanpa satu pun
bobot yang dilatih


- `MaxPooling2D((2,2))` membagi peta menjadi petak 2×2 dan menyimpan nilai terbesar di tiap petak: di nbo3 ukurannya turun $32 \rightarrow 16 \rightarrow 8 \rightarrow 4$.
- Karena hanya nilai terkuat yang disimpan, pergeseran kecil pada gambar tidak banyak mengubah hasilnya, dan perhitungan layer selanjutnya jadi lebih ringan.

Arsitektur CNN nbo3 dari ujung ke ujung



- Bagian konvolusi menyusun feature dari pixel; bagian Dense di ujung memakai feature itu untuk memilih satu dari sepuluh kelas.
- Setiap blok melihat wilayah yang lebih luas dari gambar aslinya, jadi layer awal menangkap tepi dan layer akhir menangkap bagian objek.


Augmentasi sebagai layer di dalam model



- Augmentasi menambah ragam data train tanpa gambar baru: gambar yang sama dibalik, diputar sedikit, atau di-zoom ulang tiap epoch.
- Ragamnya dipilih sesuai datanya: kucing yang dibalik tetap kucing, tetapi angka atau tulisan yang dibalik bisa berubah arti.

Aktif saat `fit()`, mati saat evaluasi.

Jebakan: Gambar train diacak sementara data validation tidak, jadi akurasi train bisa terlihat lebih rendah daripada akurasi validation di awal training. Itu efek augmentasi.



Intinya

Layer awal model gambar mempelajari hal yang umum: tepi, warna, tekstur. Bagian itu bisa dipinjam apa adanya, dan kita hanya melatih lapisan terakhir yang memutuskan kelas apa yang ada di depannya.

Mekanismenya: bekukan backbone, latih kepalanya



- Dengan `base_model.trainable = False`, backprop berhenti di batas kepala: hanya bobot kepala yang bergerak, dan bagian terbesar modelnya tetap seperti hasil latihan di ImageNet.
- Waktu per epochnya tidak otomatis kecil. Setiap gambar masih dihitung melewati seluruh ResNet50, hanya arah baliknya yang lebih pendek.
- Fine-tuning adalah langkah lanjutan: setelah kepalanya stabil, beberapa layer atas backbone dibuka dan dilatih dengan learning rate kecil.

Kapan transfer learning menolong, kapan tidak

Cocok kalau

- datanya sedikit: ribuan gambar, bukan jutaan
- resolusinya mendekati 224×224
- objeknya sejenis foto sehari-hari di ImageNet

Kurang cocok kalau

- gambarnya kecil, 32×32 seperti CIFAR-10
- domainnya jauh dari foto biasa: citra medis, radar
- datanya besar dan cukup untuk melatih CNN dari nol

Jebakan: Di nbo3, ResNet50 yang dibekukan tidak otomatis mengalahkan CNN kecil yang dilatih dari nol pada CIFAR-10: gambar 32×32 harus diperbesar dulu sebelum masuk backbone yang belajar di 224×224 . Bandingkan keduanya di data validation.

Ringkasan Act 3

- Gambar masuk ke model sebagai tabel angka. Konvolusi memanfaatkan kedekatan antar pixel yang diabaikan Dense layer.
- Satu filter kecil digeser ke seluruh gambar dan menghasilkan satu feature map. Bobot yang dibagi bersama membuat parameternya jauh lebih sedikit.
- Pooling menyusutkan peta dengan menyimpan nilai terkuat, tanpa menambah parameter.
- Blok Conv → Pool ditumpuk sampai petanya kecil, lalu Flatten dan Dense mengambil keputusan kelas.
- Augmentasi sebagai layer hanya aktif saat training. Transfer learning meminjam backbone terlatih dan melatih kepalanya, dan keunggulannya bergantung pada resolusi serta kedekatan domain.

Act 4

Bagaimana model membaca urutan?

Satu ringkasan pendek yang dibawa dari langkah ke langkah

Data berurutan: posisinya ikut membawa arti



- Mengubah urutannya mengubah artinya: urutan itu sendiri adalah informasi.
- Dense layer dan CNN memproses tiap contoh tanpa membawa apa pun dari contoh sebelumnya. Untuk urutan, model perlu tempat menyimpan yang sudah dibaca.
- nbo4 memakai gelombang sinus sebagai contoh kecil, lalu 50.000 review film IMDB yang dipotong menjadi 200 kata.


hidden state: ringkasan yang dibawa ke langkah berikutnya



Intinya

Modelnya membaca satu langkah pada satu waktu. Setiap langkah, catatan ringkasnya diperbarui dari catatan lama dan masukan baru. Yang tersimpan bukan seluruh riwayat, hanya ringkasan sepanjang beberapa puluh angka.


Mekanisme RNN: bobot yang sama dipakai di tiap langkah



sel yang sama, bobot yang sama, dipakai ulang di setiap langkah

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$$

- W_x membaca masukan langkah ini, W_h membaca ringkasan langkah sebelumnya. Keduanya tidak berubah sepanjang urutan.
- Panjang hidden state ditentukan jumlah unit: SimpleRNN(32) di nbo4 membawa 32 angka antar langkah, dan keluaran langkah terakhir dipakai memprediksi.




sinyal perbaikan dikalikan ulang di tiap langkah, dan makin tipis ke arah awal urutan

Intinya

Seperti permainan bisik berantai: makin panjang rantainya, makin sedikit pesan awal yang selamat. Review IMDB sepanjang 200 kata berarti 200 langkah, jadi kata di awal review hampir tidak lagi mempengaruhi perbaikan bobot.

LSTM: tiga gerbang yang mengatur satu catatan




- Ketiga gerbang itu bukan aturan tetap: bobotnya dilatih, jadi model belajar sendiri kapan sesuatu perlu dibuang, ditulis, atau dibaca.
- Catatan itu punya jalur yang tidak melewati perkalian bobot di tiap langkah, sehingga informasi dari awal urutan lebih tahan sampai ke akhir.
- Harganya: satu sel LSTM menyimpan lebih banyak bobot dan lebih lambat dihitung daripada SimpleRNN dengan jumlah unit sama.

GRU: versi ringkas dengan dua gerbang

Sel	Gerbang	Catatan terpisah	Parameter
SimpleRNN(32)	tidak ada	tidak	1.088
GRU(32)	update, reset	tidak	3.360
LSTM(32)	lupa, simpan, keluar	ya	4.352

- GRU menggabungkan gerbang lupa dan simpan menjadi satu gerbang update, dan tidak memisahkan catatan dari hidden state.
- Parameter di tabel dihitung untuk 32 unit dan satu feature masukan, seperti pada data sinus nbo4. Lebih sedikit bobot berarti lebih ringan per langkah.
- Pilihan antara GRU dan LSTM diselesaikan dengan mencoba keduanya dan membandingkan hasilnya di data validation, bukan dari jumlah gerbangnya.


Embedding: dari indeks kata ke vektor



isi tabelnya dilatih bersama model, bukan ditetapkan sebelumnya

- Indeks kata hanyalah nomor urut di kamus. Kata bernomor 5.000 bukan dua kali lipat kata bernomor 2.500, jadi angkanya tidak boleh masuk langsung ke layer.
- Layer *Embedding* menukar setiap indeks dengan satu baris vektor, dan barisan vektor itulah yang dibaca LSTM langkah demi langkah.
- Di nbo4 semua review disamakan menjadi 200 langkah: yang pendek ditambah 0.

Hasil nyata: SimpleRNN memprediksi nilai berikutnya



- SimpleRNN(32) membaca 20 langkah terakhir dan memprediksi satu nilai berikutnya: MAE 0,0246 pada data test, satu run, seed 42, 20 epoch.
- Pembandingnya baseline “ulangi nilai terakhir yang dilihat”, dan di nbo4 baseline itu dihitung lebih dulu supaya angka modelnya punya arti.
- Pola berulang serapi ini memang mudah; deret nyata seperti penjualan atau sensor punya tren dan gangguan.

Kapan model urutan cocok, dan apa jebakannya

Cocok kalau

- urutannya bermakna, panjangnya puluhan sampai ratusan langkah
- datanya deret waktu dari sensor
- modelnya perlu kecil, misalnya untuk perangkat edge

Kurang cocok kalau

- konteks jauh menentukan; transformer di Modul 3 dan 4 lebih cocok
- urutannya bisa diringkas menjadi feature tabular
- barisnya sebenarnya tidak berurutan

Jebakan: LSTM tidak otomatis lebih baik daripada SimpleRNN. Pada urutan pendek seperti data sinus nbo4, keduanya bisa setara sementara LSTM memakai empat kali lebih banyak bobot. Yang menentukan adalah hasil di data validation.

Ringkasan Act 4

- Pada data berurutan, posisi ikut membawa arti, jadi modelnya perlu membawa sesuatu dari langkah sebelumnya.
- RNN menyimpan hidden state: satu ringkasan pendek yang diperbarui tiap langkah dengan bobot yang sama di sepanjang urutan.
- Makin panjang urutannya, makin tipis sinyal perbaikan yang sampai ke langkah awal. Itu vanishing gradient dalam bentuk waktu.
- LSTM menambahkan catatan dengan tiga gerbang terlatih; GRU melakukan hal serupa dengan dua gerbang dan bobot lebih sedikit.
- Teks masuk lewat layer Embedding yang menukar indeks kata menjadi vektor, dan panjang urutannya disamakan lebih dulu.