

Deep Learning Fundamentals

Hari 2 · Navasena Gen-ML Course · Batch 6

6 notebook · TensorFlow dan Keras · Google Colab

Navasena AI

Peta hari 2

Dasar belajar

nbo1 Neural network pertama (Fashion-MNIST)

Aktivasi

nbo2 Fungsi aktivasi dan optimizer

Gambar

nbo3 CNN dan transfer learning (CIFAR-10)

Urutan

nbo4 RNN dan LSTM

GPU

nbo5 Mixed precision, ONNX, TensorRT

Generatif

nbo6 Autoencoder, GAN, diffusion

Dua act pertama membahas cara satu neural network belajar. Sisanya memakai dasar itu untuk gambar, urutan, GPU, dan model generatif.

Dari hari 1 ke hari 2

ML klasik (hari 1)

- Feature dipilih dan dirancang manusia: kolom umur, gaji, durasi
- Data tabular, satu baris satu contoh
- Modelnya kecil, koefisiennya bisa dibaca satu per satu

Deep learning (hari 2)

- Feature dipelajari dari data mentah: pixel, urutan kata
- Gambar, teks, dan sinyal berurutan
- Modelnya berlapis, jumlah parameternya ratusan ribu ke atas


Yang tidak berubah

Alur kerjanya sama seperti hari 1: pisahkan data train, validation, dan test; bandingkan dengan baseline; pilih model di data validation. Yang berubah adalah bentuk modelnya dan dari mana featurenya datang.

Act 1

Bagaimana neural network belajar?

Satu angka kesalahan, lalu diperbaiki sedikit demi sedikit



Intinya

Bobot adalah takaran: seberapa besar tiap masukan ikut dihitung. Bias menggeser hasilnya. Aktivasi menentukan bentuk keluaran neuron.

Dari satu neuron ke satu arsitektur



- Flatten menggelar gambar 28×28 menjadi satu baris berisi 784 angka.
- Dua hidden layer menyusun feature: layer berikutnya bekerja di atas keluaran layer sebelumnya.
- Output layer punya 10 neuron, satu untuk tiap kategori pakaian.

Yang berubah saat model belajar

Layer	Bobot	Bias	Parameter
Dense 128 (ReLU)	784×128	128	100.480
Dense 64 (ReLU)	128×64	64	8.256
Dense 10 (softmax)	64×10	10	650
Total			109.386

- Seratus ribu angka ini dimulai dari nilai acak, lalu diperbaiki selama training.
- Jumlah layer, jumlah neuron, dan learning rate kamu tentukan sebelum training; ketiganya bukan hasil training.


Loss: satu angka yang mengukur seberapa salah

$$\text{loss satu contoh} = -\log(p_{\text{kelas benar}})$$

- Model mengeluarkan satu probabilitas untuk tiap kelas. Loss hanya melihat probabilitas yang diberikan ke kelas yang benar.
- Probabilitas 0,85 untuk kelas yang benar memberi loss kecil; 0,05 memberi loss besar.
- Loss seluruh batch adalah rata-rata loss tiap contohnya. Angka inilah yang diperkecil saat training.

Namanya di Keras: `sparse_categorical_crossentropy`. Accuracy dilaporkan untuk kita baca; loss yang dipakai model untuk memperbaiki diri.

Gradient Descent pada $f(w) = (w-3)^2 + 1$



Intinya

Bentuk seluruh bukitnya tidak diketahui. Yang bisa diukur hanya kemiringan di titik sekarang; satu langkah diambil ke arah menurun, lalu diulang sampai kemiringannya mendekati nol.

Ketiga panel: fungsi sama, ukuran langkah berbeda.

Learning rate: ukuran langkah dan gejalanya


Terlalu kecil

- Loss turun, tetapi sangat lambat
- Panel kiri: 12 langkah belum sampai ke dasar
- Epoch habis sebelum modelnya selesai belajar

Terlalu besar

- Langkahnya melewati dasar, lalu menjauh
- Panel kanan: nilai w makin jauh tiap langkah
- Loss naik-turun tanpa arah, atau menjadi NaN


Jebakan: Adam memakai learning rate 0,001 sebagai nilai default. Itu titik awal yang wajar, bukan angka yang cocok untuk semua data. Kalau loss diam saja atau meledak sejak epoch pertama, ubah dulu learning ratenya sebelum menambah layer.



Intinya

Setelah loss dihitung di keluaran, tiap bobot menerima satu angka: seberapa besar sumbangannya terhadap kesalahan itu. Bobot yang menyumbang lebih banyak digeser lebih jauh.

Epoch, batch, dan satu langkah perbaikan




- Satu batch berisi 32 gambar yang dihitung bersama. Bobot diperbarui sekali untuk setiap batch.
- Satu epoch berarti seluruh data train dilewati sekali: 55.000 gambar dibagi 32 memberi 1.718 langkah perbaikan.
- Batch lebih besar membuat arah langkahnya lebih tenang, tetapi butuh memori lebih besar dan langkahnya lebih sedikit per epoch.

Angka ini dari nbo1: 55.000 data train, 5.000 validation, 10.000 test.

Kurva train dan validation dibaca berdampingan


Kurva pelatihan: Dense(128) pada Fashion-MNIST (8 epoch)



- Kedua kurva loss masih turun bersama, dan akurasi validation berhenti di sekitar 0,88.
- Kalau loss validation mulai naik sementara loss train terus turun, model mulai menghafal data train.
- Pada run ini val_loss terendah jatuh di epoch terakhir, jadi 8 epoch belum cukup untuk melihat titikbaliknya.

Overfitting: melebarnya jarak train dan validation


Overfitting vs Dropout(0.5) — 6000 sampel train, 30 epoch



- Model yang sama pada 6.000 sampel train: jaraknya 0,56 tanpa dropout dan 0,18 dengan Dropout(0,5).
- Dropout mematikan sebagian neuron secara acak tiap batch; early stopping berhenti saat val_loss tidak lagi turun.


Jebakan: Dropout hanya aktif saat training. Loss validation yang lebih rendah daripada loss train bukan keajaiban: saat evaluasi, dropoutnya dimatikan.

Normalisasi input: dari 0–255 ke 0,0–1,0



- Masukan dengan rentang besar membuat gradientnya besar juga, sehingga langkah gradient descent sulit diatur dengan satu learning rate.
- Untuk pixel, pembagiya konstanta 255. Untuk data tabular, statistik scalingnya dihitung dari data train saja, lalu dipakai apa adanya ke validation dan test.

Evaluasi multi-kelas: akurasi saja belum cukup



- Akurasi test 87,4% pada model Dense(128) di gambar ini: satu run, seed 42, data test disentuh sekali.
- Diagonal berisi prediksi yang benar. Sel di luar diagonal menunjukkan kelas apa tertukar dengan apa.
- Pasangan yang paling sering tertukar dihitung dari matriksnya, dan bisa berbeda tiap kali model dilatih ulang.
- Kelas dengan bentuk khas lebih jarang tertukar daripada kelas yang potongannya mirip.

Ringkasan Act 1


- Satu neuron menghitung jumlah berbobot dari masukannya, menambah bias, lalu melewatkannya ke aktivasi. Layer adalah kumpulan neuron seperti itu.
- Loss meringkas kesalahan menjadi satu angka. Gradient descent menurunkannya dengan langkah kecil ke arah menurun, dan backprop membagi kesalahan itu ke tiap bobot.
- Learning rate menentukan ukuran langkah: terlalu kecil membuat training lambat, terlalu besar membuatnya meledak.
- Kurva train dan validation dibaca bersama. Jarak yang melebar adalah tanda overfitting, dan dropout serta early stopping menahannya.
- Untuk klasifikasi banyak kelas, confusion matrix menunjukkan kesalahan yang tidak terlihat dari angka akurasi.

Act 2

Kenapa butuh aktivasi?

Tanpa aktivasi, seratus layer sama saja dengan satu layer

Tanpa aktivasi, tumpukan layer tetap satu garis




$$W_2 (W_1 x + b_1) + b_2 = (W_2 W_1) x + (W_2 b_1 + b_2)$$

- Hasil dua layer linear bisa ditulis ulang sebagai satu layer linear, jadi menambah layer tidak menambah bentuk yang bisa dipelajari.
- nbo2 memakai model tanpa aktivasi sebagai baseline linear, lalu membandingkannya dengan model yang beraktivasi.

Empat aktivasi dan turunannya

Fungsi Aktivasi dan Turunannya



- Baris atas fungsinya, baris bawah turunannya. Turunan inilah yang dipakai backprop.
- Daerah merah menandai tempat turunannya mendekati nol; bobot di sana hampir tidak berubah.




yang sampai ke layer 1: sekitar 0,016

Intinya

Turunan sigmoid paling besar 0,25. Saat kesalahan dibagi ke belakang melewati banyak layer, angkanya dikalikan berulang dan mengecil cepat, sehingga layer paling awal hampir tidak ikut belajar.

ReLU: turunannya tetap 1 di sisi positif

ReLU




$$f(x) = \max(0, x)$$

Leaky ReLU




- ReLU meneruskan nilai positif apa adanya dan menolak yang negatif. Turunannya 1 di sisi positif, jadi kesalahan tidak menyusut saat dibagi ke belakang.
- Perhitungannya juga murah: satu perbandingan dengan nol per neuron.
- Sisi negatifnya nol. Neuron yang masukannya negatif terus berhenti diperbarui, dan keadaan itu disebut dead ReLU.
- Leaky ReLU memberi kemiringan kecil di sisi negatif, 0,1 pada gambar sebelumnya, sehingga masih ada gradient yang mengalir.

Softmax: skor mentah menjadi probabilitas



- Softmax bekerja pada seluruh output layer sekaligus: skor 2,0; 1,0; dan 0,1 menjadi 0,66; 0,24; dan 0,10, dengan total tepat 1.
- Selisih skor satu poin menjadi selisih probabilitas yang cukup besar, karena skornya lewat fungsi eksponensial dulu.
- Untuk dua kelas, satu keluaran dengan sigmoid sudah cukup. Untuk regresi, output layer dibiarkan tanpa aktivasi.



Intinya

SGD melangkah menurut kemiringan saat itu saja. Momentum menambahkan sisa arah langkah sebelumnya, sehingga jalurnya tidak banyak berbelok. Adam menyimpan rata-rata arah dan besar gradient, lalu menyesuaikan ukuran langkah tiap parameter.

Kapan mengganti aktivasi atau optimizer default

Cocok kalau

- banyak neuron ReLU berhenti aktif, keluarannya nol terus
- loss diam sejak epoch awal padahal datanya sudah dinormalisasi
- jaringannya dalam dan layer awalnya hampir tidak berubah

Kurang cocok kalau

- lossnya belum turun karena learning ratenya belum disesuaikan
- perbandingannya belum diuji di data validation
- modelnya masih underfit dan layernya memang terlalu sedikit

Jebakan: Dead ReLU biasanya berawal dari learning rate yang terlalu besar, bukan dari ReLU itu sendiri. Kalau lossnya tidak turun, ganti learning rate-nya dulu, sebelum arsitekturnya.

Ringkasan Act 2

- Aktivasi adalah bagian yang membuat tumpukan layer bisa mempelajari pola melengkung. Tanpa aktivasi, hasil akhirnya tetap satu layer linear.
- Sigmoid dan tanh punya turunan yang mengecil di kedua ujung, sehingga kesalahan menyusut saat dibagi ke belakang melewati banyak layer.
- ReLU menjaga turunannya tetap 1 di sisi positif dan murah dihitung, jadi dipakai sebagai pilihan awal untuk hidden layer. Leaky ReLU menyisakan gradient kecil di sisi negatif.
- Softmax dipakai di output layer klasifikasi banyak kelas; sigmoid untuk dua kelas; tanpa aktivasi untuk regresi.
- Optimizer hanya mengubah cara melangkah, bukan bukitnya. Adam menjadi titik awal yang wajar, dan learning ratenya tetap perlu diperiksa.