



Apa itu NLP

- Natural Language Processing: cabang AI agar komputer memahami & memproses bahasa manusia
- Bukan sekadar string manipulation
- Input: teks atau suara (speech); lintas bahasa (EN, ID, Mandarin)
- Contoh: Google Translate, Siri, ChatGPT, search engine

➤ memahami ruang lingkup NLP

Tokenization

- Token = unit terkecil (kata, sub-kata, atau karakter)
- Contoh: 'Saya belajar NLP' -> 3 token
- Bahasa Indonesia lebih sulit karena imbuhan kaya
- NLTK pakai word\_tokenize(); spaCy cukup nlp(text)

```
from nltk import word_tokenize;
word_tokenize(text)
```

➤ langkah pertama preprocessing teks

Stopword Removal

- Hapus kata umum tak bermakna (yang, di, dari, dan)
- Fokus pada kata bermakna agar model lebih akurat
- EN: NLTK stopwords.words('english')
- ID praktiknya pakai nlp-id StopWord().get\_stopword(); NLTK 'indonesian' alternatif valid

```
from nlp_id.stopword import StopWord;
StopWord().get_stopword()
```

➤ membersihkan noise sebelum analisis/klasifikasi

Lemmatization vs Stemming

- Lemmatization: kata -> bentuk dasar kamus (menjalankan -> jalan)
- Lebih akurat dari stemming karena hasilnya kata valid
- ID: nlp-id Lemmatizer().lemmatize(); Sastrawi untuk stemming
- Tantangan ID: imbuhan me-, -kan, -i, pe-, -an, ber-

```
from nlp_id.lemmatizer import Lemmatizer;
Lemmatizer().lemmatize("saya menjalankan") # ->
"saya jalan" (string, lowercase)
```

➤ normalisasi kata berimbuhan ke bentuk dasar

POS Tagging

- POS = Part of Speech: menandai kelas kata tiap token
- spaCy (EN) -> tag set Universal Dependencies: PRON, VERB, NOUN, ADP
- nlp-id (ID) -> tagset Indonesia (mirip Penn Treebank): NNP, VB, NN, IN, ADV (beda dari label UD ilustratif di slide)
- Penting untuk machine translation, QA, information extraction

```
from nlp_id.postag import PosTag;
PosTag().get_pos_tag(text)
```

➤ analisis struktur gramatikal kalimat

Named Entity Recognition (NER)

- Identifikasi entitas: PERSON (orang), ORG (organisasi), LOC (lokasi)
- Contoh: 'Budi Santoso' -> PERSON, 'Navasena' -> ORG, 'Jakarta' -> LOC
- spaCy paling umum untuk NER bahasa Inggris
- Output dipakai untuk ekstraksi informasi terstruktur

```
for ent in nlp(text).ents: print(ent.text,
ent.label_)
```

➤ ekstrak nama orang/tempat/organisasi dari teks

Sentiment Analysis

- Deteksi emosi/opini: skala negatif <-> positif
- TextBlob (EN): polarity in [-1.0, 1.0], subjectivity in [0.0, 1.0]
- ID: IndoBERT atau pendekatan lexicon
- Use case: review produk, brand monitoring

```
from textblob import TextBlob;
TextBlob(text).sentiment.polarity
```

➤ mengukur opini/emosi pada review atau komentar

Text Classification (Spam vs Ham)

- Input email/teks -> output label: spam atau ham (bukan spam)
- Algoritma umum: Naive Bayes
- Butuh data training berlabel
- NLTK: NaiveBayesClassifier; dataset demo movie\_reviews

```
from nltk import NaiveBayesClassifier;
NaiveBayesClassifier.train(train)
```

➤ kategorisasi teks (spam filter, sortir berita)

Tantangan EN vs ID

- EN: morfologi sederhana, word order tetap (SVO), imbuhan terbatas (-s, -ed, -ing)
- ID: imbuhan kaya (jalan -> menjalani -> dijalankan), banyak loanword serapan
- Library beda per bahasa
- EN: nltk + spacy; ID: nlp-id + Sastrawi

➤ memilih tooling sesuai bahasa target

Dari Kata ke Vektor

- TF-IDF: vektor hitungan kata – buta sinonim ("suka" != "gemar")
- Embedding: vektor makna; sinonim -> vektor berdekatan
- cosine\_similarity(emb\_query, emb\_dokumen) -> semantic search
- Inti RAG di Module 05 (di sana ditambah FAISS)

➤ Fondasi retrieval & RAG

Subword & IndoBERT

- LLM memakai subword (BPE/WordPiece): "mempelajari" dipecah jadi potongan
- Kalimat Indonesia lebih banyak token di tokenizer English-centric
- IndoBERT via pipeline("sentiment-analysis") – tahan bahasa gaul
- Ekosistem ID: IndoNLU, IndoLEM, NusaBERT

➤ Jembatan langsung ke Module 04 (LLM)

Quick-Ref Library / Tool NLP

| Library   | Bahasa  | Fungsi utama                              | API contoh                                        |
|-----------|---------|-------------------------------------------|---------------------------------------------------|
| NLTK      | EN + ID | Tokenize, stopwords, klasifikasi          | word_tokenize(), NaiveBayesClassifier             |
| spaCy     | EN      | NER, POS, dependency parsing              | nlp(text), token.pos_, doc.ents                   |
| TextBlob  | EN      | Sentiment (polarity, subjectivity)        | TextBlob(text).sentiment                          |
| Sastrawi  | ID      | Stemming bahasa Indonesia                 | StemmerFactory().create_stemmer()                 |
| nlp-id    | ID      | Tokenizer, POS tag, lemmatizer, stopwords | PosTag().get_pos_tag(), StopWord().get_stopword() |
| IndoBERT  | ID      | Sentiment / klasifikasi (model)           | transformers pipeline                             |
| wordcloud | EN + ID | Visualisasi word frequency                | WordCloud().generate(text)                        |

Istilah Kunci

**Token** – Unit terkecil teks hasil tokenization (kata, sub-kata, atau karakter).

**Stopword** – Kata umum tak bermakna yang dibuang (EN: the, is; ID: yang, di, dari, dan).

**Lemmatization** – Mengubah kata ke bentuk dasar kamus yang valid (menjalankan -> jalan).

**Stemming** – Memotong imbuhan ke akar kata, hasil bisa bukan kata kamus; Sastrawi untuk ID.

**POS (Part of Speech)** – Kelas kata tiap token; spaCy pakai tag UD (NOUN, VERB), nlp-id pakai Penn-Treebank ID (NN, VB, NNP).

**NER** – Named Entity Recognition: deteksi entitas PERSON, ORG, LOC dalam teks.

**Polarity** – Skor sentimen TextBlob dari -1.0 (negatif) sampai +1.0 (positif).

**Naive Bayes** – Algoritma probabilistik umum untuk text classification (mis. spam vs ham).

**Embedding** – Vektor angka yang merepresentasikan makna teks.

**Cosine similarity** – Ukuran kedekatan dua vektor (1 = searah/semakna).

**Subword** – Potongan kata yang menjadi satuan token LLM (BPE/WordPiece).

**TF-IDF** – Bobot kata berdasarkan frekuensi di dokumen vs keseluruhan corpus.