

# Module 03

## NLP Fundamentals

Natural Language Processing dengan Python



# Act 1


## Apa itu NLP?

Bagaimana komputer memahami bahasa manusia?

# Definisi NLP

- ▶ **Natural Language Processing**
- ▶ Cabang AI yang membuat komputer **memahami** & **memproses** bahasa manusia
- ▶ Bukan sekadar string manipulation
- ✓ Bahasa: Inggris, Indonesia, Mandarin, dll
- ✓ Bentuk: teks, suara (speech)

Contoh: Google Translate, Siri, ChatGPT, search engine



# Aplikasi NLP di Dunia Nyata

- ✓ **Search engines** (Google, Bing) → memahami query
- ✓ **Machine translation** (Google Translate) → lintas bahasa
- ✓ **Sentiment analysis** → review produk, monitoring brand
- ✓ **Chatbots & assistants** (Siri, Alexa) → percakapan
- ✓ **Text classification** → spam filter, kategorisasi berita
- ✓ **Summarization** → ringkasan otomatis dokumen



# Tantangan Bahasa Manusia

## Bahasa Inggris:

- ▶ Morphology sederhana  
run → runs → running
- ▶ Word order tetap (SVO)
- ▶ Imbuhan terbatas (-s, -ed, -ing)

## Bahasa Indonesia:

- ▶ Imbuhan kaya  
jalan → menjalani → menjalankan → dijalankan
- ▶ Affixes: me-, -kan, -i, pe-, -an, ber-
- ▶ Loanwords (serapan)


Library berbeda dibutuhkan untuk bahasa berbeda: `nltk` + `spacy` untuk Inggris, `nlp-id` + `Sastrawi` untuk Indonesia

## Act 2

# Text Preprocessing

Membersihkan teks sebelum diproses ML

# Pipeline NLP: Dari Teks ke Model



Tahapan utama: dari teks mentah sampai siap masuk model ML

# Tokenization: Memecah Teks

"Saya belajar NLP di Navasena."



Saya

belajar

NLP

di

Navasena

.

- ▶ **Token** = unit terkecil (kata, sub-kata, atau karakter)
- ▶ Contoh: "Saya belajar NLP" → 3 token
- ▶ Bahasa Indonesia: lebih challenging karena imbuhan
- ✓ NLTK: `word_tokenize()`
- ✓ spaCy: `nlp(text)`



# Stopword & Lemmatization

## Stopword Removal

- ▶ Hapus kata-kata umum (yang, di, dari, dan)
- ▶ Fokus pada kata **bermakna**
- ✓ NLTK: `stopwords.words('indonesian')`
- ✓ nlp-id: punya list bawaan

```
["saya", "belajar", "NLP",  
"di", "Navasena"]
```

↓

```
["belajar", "NLP", "Navasena"]
```

## Lemmatization

- ▶ Kata → bentuk dasar
- ▶ menjalankan → jalan
- ▶ kebersihan → bersih
- ✓ Lebih akurat dari *stemming* (beri bentuk kamus)
- ✓ nlp-id: `Lemmatizer().lemmatize()`

```
["menjalankan", "membaca", "kebersihan"]
```

↓

```
["jalan", "baca", "bersih"]
```

## Act 3

# Analisis & Visualisasi

Melihat pola dalam teks



# POS Tagging: Menandai Kelas Kata

"Saya membaca buku di perpustakaan."



- ▶ **POS** = Part of Speech
- ▶ Kelas kata: **PRON** (ganti), **VERB** (kerja), **NOUN** (benda), **ADP** (preposisi)
- ▶ Penting untuk:
  - ▶ Machine translation
  - ▶ Question answering
  - ▶ Information extraction

# Word Frequency: EN vs ID



Stopword bahasa Inggris: the, is, are, dan

Stopword Indonesia: yang, di, dari,

# Named Entity Recognition (NER)

"Achmad Zaenuri bekerja di Navasena di Jakarta sejak 2024."

Achmad Zaenuri

PERSON

bekerja

VERB

di

Navasena

ORG

di

Jakarta

LOC

✓ **PERSON** (nama orang) · **ORG** (organisasi) · **LOC** (lokasi)

## Act 4

# Sentiment & Classification

Mengenali opini dalam teks

# Sentiment Analysis

- ▶ Mendeteksi **emosi** / **opini** dalam teks
- ▶ Skala: **negatif**  $\leftrightarrow$  **positif**
- ▶ Library Python:
  - ▶ TextBlob (Inggris)
  - ▶ IndoBERT / lexicon (Indonesia)



**TextBlob:**  $\text{polarity} \in [-1.0, 1.0]$  ·  $\text{subjectivity} \in [0.0, 1.0]$

# Text Classification: Spam vs Ham

## Contoh: email spam filter

- ▶ Input: email baru
- ▶ Output: **spam** atau **ham** (**bukan spam**)
- ▶ Algoritma umum: **Naive Bayes**
- ▶ Butuh: data training (email yang sudah dilabeli)





# Notebook 01: NLP Fundamentals (EN)

## Topik:

- ▶ Basic text processing
- ▶ Named Entity Recognition
- ▶ Sentiment analysis
- ▶ Word frequency
- ▶ Text classification (Naive Bayes)

## Library:

- ▶ `nltk` — text processing dasar
- ▶ `spacy` — NER, POS, dependency
- ▶ `textblob` — sentiment
- ▶ `wordcloud` — visualisasi
- ▶ `nltk.NaiveBayesClassifier` — klasifikasi

**Dataset:** `movie_reviews` (NLTK corpus) — review film positif/negatif

# Notebook 01: NLP Fundamentals (ID)

## Topik:

- ▶ Text preprocessing pipeline
- ▶ POS Tagging Indonesia
- ▶ Phrase tokenization
- ▶ Word frequency
- ▶ Stopword analysis
- ▶ Lemmatization
- ▶ Complete text analysis

## Library:

- ▶ `nltk` — text processing dasar
- ▶ `Sastrawi` — stemming Indonesia
- ▶ `nlp-id` — tokenizer & POS
- ▶ `pandas` — tabular data

**Fokus:** tantangan morfologi Indonesia (imbuhan `me-`, `-kan`, `-i`, `pe-`, `-an`)

## Act 5

# Ringkasan & Lanjutan

Apa selanjutnya?

# Ringkasan Modul 03

| #  | Topik            | Tujuan                       |
|----|------------------|------------------------------|
| 1  | Definisi NLP     | Memahami ruang lingkup       |
| 2  | Aplikasi         | Melihat penggunaan nyata     |
| 3  | Tantangan bahasa | ID vs EN comparison          |
| 4  | Pipeline         | Tokenize → clean → vectorize |
| 5  | Tokenization     | Memecah teks                 |
| 6  | Stopword & Lemma | Normalisasi kata             |
| 7  | POS Tagging      | Menandai kelas kata          |
| 8  | Word frequency   | Analisis kata populer        |
| 9  | NER              | Ekstrak entitas              |
| 10 | Sentiment        | Deteksi opini                |
| 11 | Classification   | Spam vs ham                  |

# Setup & Tools

## Install library:

```
1 !pip install nltk spacy textblob
2 !pip install Sastrawi nlp-id
3 !python -m spacy download
   en_core_web_sm
```

## Untuk Colab:

- ▶ Runtime → Change runtime type → CPU cukup
- ▶ Tidak perlu GPU untuk NLP dasar
- ▶ Library di-install per-notebook
- ▶ Data dari `nltk.download()` atau upload sendiri

## Lanjutan: Modul 04 – LLM

- ✓ Module 04: **Large Language Models** dengan Transformers
- ✓ Module 05: **RAG** (Retrieval-Augmented Generation)
- ✓ Module 06: NVIDIA ecosystem (TensorRT, NeMo, RAG)



# Terima Kasih!

Pertanyaan? Diskusi?

**NLP Fundamentals** · Modul 03  
Navasena Gen-ML Course