

Module 03

NLP Fundamentals

Natural Language Processing dengan Python



Act 1


Apa itu NLP?

Bagaimana komputer memahami bahasa manusia?

Definisi NLP

- ▶ **Natural Language Processing**
- ▶ Cabang AI yang membuat komputer **memahami** & **memproses** bahasa manusia
- ▶ Bukan sekadar string manipulation
- ✓ Bahasa: Inggris, Indonesia, Mandarin, dll
- ✓ Bentuk: teks, suara (speech)

Contoh: Google Translate, Siri, ChatGPT, search engine



Aplikasi NLP di Dunia Nyata

- ✓ **Search engines** (Google, Bing) → memahami query
- ✓ **Machine translation** (Google Translate) → lintas bahasa
- ✓ **Sentiment analysis** → review produk, monitoring brand
- ✓ **Chatbots & assistants** (Siri, Alexa) → percakapan
- ✓ **Text classification** → spam filter, kategorisasi berita
- ✓ **Summarization** → ringkasan otomatis dokumen



Tantangan Bahasa Manusia

Bahasa Inggris:

- ▶ Morphology sederhana
run → runs → running
- ▶ Word order tetap (SVO)
- ▶ Imbuhan terbatas (-s, -ed, -ing)

Bahasa Indonesia:

- ▶ Imbuhan kaya
jalan → menjalani → menjalankan → dijalankan
- ▶ Affixes: me-, -kan, -i, pe-, -an, ber-
- ▶ Loanwords (serapan)


Library berbeda dibutuhkan untuk bahasa berbeda: `nltk` + `spacy` untuk Inggris, `nlp-id` untuk Indonesia

Act 2

Text Preprocessing

Membersihkan teks sebelum diproses ML

Pipeline NLP: Dari Teks ke Model



Tahapan utama: dari teks mentah sampai siap masuk model ML

Tokenization: Memecah Teks

"Saya belajar NLP di Navasena."



Saya

belajar

NLP

di

Navasena

.

- ▶ **Token** = unit terkecil (kata, sub-kata, atau karakter)
- ▶ Contoh: "Saya belajar NLP" → 3 token
- ▶ Imbuhan membuat lemmatization/stemming Indonesia lebih menantang
- ✓ NLTK: `word_tokenize()`
- ✓ spaCy: `nlp(text)`

Stopword & Lemmatization

Stopword Removal

- ▶ Hapus kata-kata umum (yang, di, dari, dan)
- ▶ Fokus pada kata **bermakna**
- ✓ NLTK: `stopwords.words('indonesian')`
- ✓ nlp-id: punya list bawaan

```
["saya", "belajar", "NLP",  
"di", "Navasena"]
```

↓

```
["belajar", "NLP", "Navasena"]
```

Lemmatization

- ▶ Kata → bentuk dasar
- ▶ menjalankan → jalan
- ▶ kebersihan → bersih
- ✓ Lebih akurat dari *stemming* (beri bentuk kamus)
- ✓ nlp-id: `Lemmatizer().lemmatize()`

```
["menjalankan", "membaca", "kebersihan"]
```

↓

```
["jalan", "baca", "bersih"]
```


Act 3

Analisis & Visualisasi

Melihat pola dalam teks

POS Tagging: Menandai Kelas Kata



"Saya membaca buku di perpustakaan."



Catatan: label di slide memakai tagset UD (ilustratif); nlp-id memakai NNP/VB/NN/IN.

- ▶ **POS** = Part of Speech
- ▶ Kelas kata: **PRON** (ganti), **VERB** (kerja), **NOUN** (benda), **ADP** (preposisi)
- ▶ Penting untuk:
 - ▶ Machine translation
 - ▶ Question answering
 - ▶ Information extraction

Word Frequency: EN vs ID



Stopword bahasa Inggris: the, is, are
dan

Stopword Indonesia: yang, di, dari,

Named Entity Recognition (NER)

"Budi Santoso bekerja di Navasena di Jakarta sejak 2024."

Budi Santoso

PERSON

bekerja

VERB

di

Navasena

ORG

di

Jakarta

LOC

✓ **PERSON** (nama orang) · **ORG** (organisasi) · **LOC** (lokasi)

spaCy melabeli kota/negara sebagai GPE (bukan LOC).

Act 4

Sentiment & Classification

Mengenali opini dalam teks

Sentiment Analysis

- ▶ Mendeteksi **emosi** / **opini** dalam teks
- ▶ Skala: **negatif** $\leftrightarrow$ **positif**
- ▶ Library Python:
 - ▶ TextBlob (Inggris)
 - ▶ IndoBERT / lexicon (Indonesia)



TextBlob: $\text{polarity} \in [-1.0, 1.0]$ · $\text{subjectivity} \in [0.0, 1.0]$

Text Classification: Spam vs Ham

Contoh: email spam filter

- ▶ Input: email baru
- ▶ Output: **spam** atau **ham (bukan spam)**
- ▶ Algoritma umum: **Naive Bayes**
- ▶ Butuh: data training (email yang sudah dilabeli)



Notebook 01: NLP Fundamentals (EN)

Topik:

- ▶ Basic text processing
- ▶ Named Entity Recognition
- ▶ Sentiment analysis
- ▶ Word frequency
- ▶ Text classification (Naive Bayes)

Library:

- ▶ `nltk` — text processing dasar
- ▶ `spacy` — NER, POS, dependency
- ▶ `textblob` — sentiment
- ▶ `wordcloud` — visualisasi
- ▶ `nltk.NaiveBayesClassifier` — klasifikasi

Dataset: `movie_reviews` (NLTK corpus) — review film positif/negatif

Notebook 01: NLP Fundamentals (ID)

Topik:

- ▶ Text preprocessing pipeline
- ▶ POS Tagging Indonesia
- ▶ Phrase tokenization
- ▶ Word frequency
- ▶ Stopword analysis
- ▶ Lemmatization
- ▶ Complete text analysis
- ▶ Vektor & semantic search
- ▶ Subword tokenization (LLM)
- ▶ Sentiment IndoBERT

Library:

- ▶ `nltk` — text processing dasar
- ▶ `nlp-id` — tokenizer, POS, lemmatizer
- ▶ `pandas` — tabular data
- ▶ `sentence-transformers` — embedding
- ▶ `transformers` — IndoBERT pipeline

Fokus: tantangan morfologi Indonesia (imbuhan `me-`, `-kan`, `-i`, `pe-`, `-an`)

Act 5

Dari Kata ke Vektor

Jembatan menuju LLM (Module 04) dan RAG (Module 05)

Dari Menghitung Kata ke Memahami Makna

TF-IDF / Bag-of-Words

- ▶ Vektor = hitungan kata
- ▶ “suka” dan “gemar” dianggap TIDAK berhubungan
- ▶ Baseline klasik, murah, cepat

Embedding

- ▶ Vektor makna, belajar dari jutaan kalimat
- ▶ Sinonim → vektor berdekatan
- ▶ sentence-transformers multilingual

Kedekatan diukur dengan **cosine similarity** — semantic search: cari dokumen berdasarkan MAKNA query ⇒ inti RAG di Module 05

Subword Tokenization: Token ala LLM

```
1 tok = AutoTokenizer.from_pretrained("gpt2")  
2 tok.tokenize("mempelajari")  
3 # ['mem', 'pel', 'aj', 'ari'] (potongan subword!)
```

- ▶ Kosakata terbatas (~30–50 ribu subword) bisa menulis kata APA PUN
- ▶ Tokenizer English-centric memecah kata Indonesia jadi lebih banyak token
→ kalimat Indonesia “lebih mahal” di API per-token
- ▶ Mulai Module 04: “token” = subword ini, bukan kata utuh

Sentiment Indonesia dengan IndoBERT

```
1 sentimen = pipeline("sentiment-analysis",  
2     model="w11wo/indonesian-roberta-base-sentiment-classifier")  
3 sentimen("Gw suka bgt sama teknologi NLP nih")  
4 # [{'label': 'positive', 'score': 0.99}]
```

- ▶ Transformer fine-tuned untuk bahasa Indonesia — tahan bahasa gaul
- ▶ Pola transfer learning yang sama dengan ResNet di Module 02
- ▶ Ekosistem: IndoBERT, IndoNLU, IndoLEM, NusaBERT (Hugging Face Hub)

⇒ pipeline yang sama menjadi pintu masuk ke LLM di Module 04

Act 6

Ringkasan & Lanjutan

Apa selanjutnya?

Ringkasan Modul 03

#	Topik	Tujuan
1	Definisi NLP	Memahami ruang lingkup
2	Aplikasi	Melihat penggunaan nyata
3	Tantangan bahasa	ID vs EN comparison
4	Pipeline	Tokenize → clean → vectorize
5	Tokenization	Memecah teks
6	Stopword & Lemma	Normalisasi kata
7	POS Tagging	Menandai kelas kata
8	Word frequency	Analisis kata populer
9	NER	Ekstrak entitas
10	Sentiment	Deteksi opini
11	Classification	Spam vs ham
12	Vektor & embedding	TF-IDF vs makna, semantic search
13	Subword tokenization	Token ala LLM (BPE)
14	IndoBERT	Sentiment Indonesia via transformer

Setup & Tools

Install library:

```
1 !pip install nltk spacy textblob
2 !pip install nlp-id
3 !python -m spacy download
   en_core_web_sm
```

Untuk Colab:

- ▶ Runtime → Change runtime type → CPU cukup
- ▶ Tidak perlu GPU untuk NLP dasar
- ▶ Library di-install per-notebook
- ▶ Data dari `nltk.download()` atau upload sendiri

NLP on Steroids: NVIDIA RAPIDS

Stack RAPIDS untuk NLP

- ▶ **cuDF** — pandas versi GPU
- ▶ **nvtext** — tokenize, n-gram, minhash di GPU
- ▶ **cuML** — scikit-learn versi GPU
- ▶ Pre-installed di Colab (runtime GPU)

Kapan GPU menang?

- ▶ Data besar (puluhan ribu dokumen ke atas)
- ▶ Operasi string yang seragam & masif
- ▶ Overhead transfer CPU→GPU tertutupi


Hands-on: `notebook 02_nlp_on_steroids`

Zero Code Change: cudf.pandas & cuml.accel

```
1 # CPU: pandas + sklearn biasa
2 python pipeline.py
3
4 # GPU: file SAMA, nol perubahan kode
5 python -m cudf.pandas -m cuml.accel pipeline.py
```

- ▶ `cudf.pandas`: operasi pandas dialihkan ke GPU, sisanya *fallback* otomatis ke CPU
- ▶ `cuml.accel`: estimator scikit-learn → cuML di GPU
- ▶ Akurasi identik — yang berubah hanya **waktu**

Seberapa Cepat? (Colab T4, 150 ribu paragraf Wikipedia ID)



Diukur langsung di notebook 02_nlp_on_steroids — angka di mesinmu bisa sedikit berbeda.

Lanjutan: Modul 04 – LLM

- ✓ Module 04: **Large Language Models** dengan Transformers
- ✓ Module 05: **RAG** (Retrieval-Augmented Generation)
- ✓ Module 06: NVIDIA ecosystem (TensorRT, NeMo, GPU optimization)



Terima Kasih!

Pertanyaan? Diskusi?

NLP Fundamentals · Modul 03
Navasena Gen-ML Course