


LLM Fundamentals

Mengenal Large Language Models (LLM) berbasis Transformer: cara kerjanya dari tokenization sampai generation, dan cara memakainya lewat HuggingFace transformers untuk klasifikasi teks, chatbot, dan few-shot.



NLP vs LLM

- NLP = bidang luas pemrosesan bahasa
- LLM = Large Language Model, satu jenis model NLP
- Dilatih pada teks masif (miliaran kata) + arsitektur transformer
- 1 LLM mengerjakan banyak tugas tanpa dilatih ulang per tugas

► memahami posisi LLM di dalam NLP

Skala & Evolusi

- Evolusi: n-gram -> RNN/LSTM -> Transformer (2017)
- Transformer proses kata paralel via attention, bukan satu per satu (RNN)
- Makin banyak parameter -> makin mampu (sampai titik tertentu)
- Data, arsitektur & fine-tuning sama pentingnya; BERT 110M -> GPT-3 175B

Tokenization

- Model baca token, bukan huruf/kata utuh
- Token sering subword (potongan kata); tiap token -> ID angka
- Kata umum = 1 token; kata jarang dipecah jadi beberapa
- Semua teks diubah jadi token ID dulu

► langkah pertama mengubah teks jadi angka

Embedding & Transformer

- Tiap token ID -> embedding (vektor angka)
- Kata mirip makna -> vektor mirip
- Vektor diproses berlapis lewat transformer block
- Output = prediksi token berikutnya

Attention

- Model 'memperhatikan' kata paling relevan saat proses 1 kata
- Menimbang semua kata lain, tidak sama rata
- Belajar 'itu' merujuk ke 'buku', bukan 'meja'
- Kunci paham konteks kalimat panjang

► menjaga konteks pada kalimat panjang

Generation & Sampling

- LLM autoregressive: prediksi 1 token lalu ulang
- Token baru jadi input token selanjutnya
- temperature rendah = fokus; tinggi = kreatif/acak
- do_sample=True -> sampling acak-terbobot (vs greedy)

```
model.generate(**inputs, do_sample=True, temperature=0.7)
```

► atur keseimbangan fokus vs kreativitas output

pipeline vs Load Manual

- pipeline: cepat, cukup sebut task + nama model
- AutoModel + AutoTokenizer: manual, lebih fleksibel & terkontrol
- pipeline cocok eksperimen cepat
- Manual: kontrol penuh tokenizer & inference

```
pipe = pipeline("text-generation", model="facebook/opt-350m")
```

► pipeline untuk cepat, manual untuk fleksibel

Model Gated & Login HF

- Sebagian model gated, contoh Llama-2 dari Meta
- Perlu setuju lisensi + token akses HuggingFace
- Login dulu sebelum download
- Tujuan: lisensi, kontrol penggunaan, verifikasi pengguna

```
!huggingface-cli login
```

► akses model dengan akses dibatasi (gated)

Text Classification

- pipeline('sentiment-analysis') di atas AutoModelForSequenceClassification
- prajjwal1/bert-tiny belum punya head klasifikasi terlatih
- Akibatnya label LABEL_0/LABEL_1, score ~0.5 (tebakan acak)
- Sentimen nyata: pakai model fine-tuned (mis. distilbert di SST-2)

```
pipeline("sentiment-analysis", model="prajjwal1/bert-tiny")
```

► klasifikasi sentimen / kategori teks

Chatbot dengan Gradio

- gr.ChatInterface buat tampilan chat siap pakai
- Fungsi menyusun prompt 'User: ... \nAssistant:'
- Parameter history disediakan Gradio (di contoh ini diabaikan)
- launch(share=True) beri tautan publik

```
gr.ChatInterface(chatbot_response).launch(share=True)
```

► buat UI percakapan cepat dari LLM

Few-shot Learning

- Beri beberapa contoh langsung di dalam prompt
- Tanpa melatih ulang, model meniru pola Question/Answer
- Pertanyaan baru dibiarkan kosong agar dilanjutkan model
- Prompt lebih panjang -> naikan max_length

```
Question: capital of France?\nAnswer: Paris.\nQuestion: capital of Italy?\nAnswer: <- model melanjutkan
```

► arahkan model lewat contoh, bukan perintah

Evaluation & Setup

- Jalankan test prompt; catat prompt, response, panjang (len split)
- Model kecil: opt-350m, bert-tiny, TinyLlama-1.1B; gated (konsep): Llama-2-7b-chat-hf
- float16 -> bobot ~setengah memori vs float32; butuh GPU (Colab T4)
- LLM bisa halusinasi & punya knowledge cutoff -> RAG (Module 05)

```
AutoModelForCausalLM.from_pretrained("facebook/opt-t-350m", device_map="auto", torch_dtype=torch.float16)
```

► ukur output & hemat memori GPU

Quick-Ref Library & Model

Topik	Library/Model	Tujuan
LLM inference	transformers (facebook/opt-350m)	Generasi teks dari prompt
pipeline vs manual	pipeline() vs AutoModel (TinyLlama-1.1B-Chat)	2 cara load & jalankan model
Text classification	prajjwal1/bert-tiny	Klasifikasi sentimen (head ilustratif)
Chatbot interface	Gradio (gr.ChatInterface)	UI percakapan sederhana
Few-shot learning	facebook/opt-350m	Beri contoh di prompt, model meniru
Model evaluation	transformers (fungsi sendiri)	Uji respons & ukur panjang output

Istilah Kunci

LLM — Large Language Model: model NLP raksasa berbasis transformer, dilatih pada teks masif.

Token — Potongan teks (sering subword) yang dipetakan ke ID angka untuk dibaca model.

Embedding — Vektor angka mewakili token; kata mirip makna -> vektor mirip.

Attention — Mekanisme model menimbang kata mana yang paling relevan saat memproses kalimat.

Transformer — Arsitektur (2017) yang memproses kata paralel via attention, dasar LLM modern.

Autoregressive — Cara generasi: prediksi 1 token, jadikan input berikutnya, ulang terus.

Temperature — Parameter sampling: rendah = fokus/deterministik, tinggi = kreatif/acak.

Gated model — Model dengan akses dibatasi (mis. Llama-2) yang butuh setuju lisensi + token HF.