


RAG Fundamentals

RAG membekali LLM dengan konteks faktual dari dokumenmu (embed → retrieve → rerank → generate) sebelum menjawab – halusinasi berkurang, jawaban bisa di-update tanpa latih ulang, dan setiap klaim bisa disitasi. Ringkasan delapan notebook konsep.



① Fundamentals

- LLM polos: **halusinasi** + **knowledge cutoff**
- RAG = **Retrieve** (cari konteks) + **Generate** (LLM jawab)
- Embed multilingual → cari **makna**, bukan kata
- Tambah pengetahuan = tambah dokumen (tanpa latih ulang)

► embed → retrieve → generate

② Ingest & Chunk

- **Docling**: PDF → struktur (heading, tabel) + OCR
- **HybridChunker**: potong sesuai struktur, tiap chunk ≤ batas token
- Simpan **halaman + heading** tiap chunk → bahan sitasi
- Embed versi *contextualize* (heading + teks), bukan teks polos

► ingest baik = retrieval baik

③ Retrieve Better (Rerank)

- **Bi-encoder** + FAISS: cepat, ambil 20 kandidat
- **Cross-encoder** rerank: akurat, urutkan ulang → top-4
- Model: **bge-reranker-v2-m3** (multilingual)
- Reranker menilai *relevansi topik*, bukan menjamin jawaban ada di konteks

► presisi konteks naik

④ Ukur (RAGAS)

- Retrieval: **Context Precision**, **Context Recall**
- Jawaban: **Faithfulness** (anti-ngarang), **Answer Relevancy**
- Judge harus kuat → **NVIDIA NIM** (Llama-3.3-70B)
- Model kecil sering gagal parsing JSON → skor NaN

► tahu di mana yang lemah

⑤ Skala Index

- **Flat** (exact, recall 100%) · **IVF/HNSW** (perkiraan, cepat)
- Cosine: *normalize_L2* dulu lalu **IndexFlatIP**
- Persist: FAISS *write_index* / ChromaDB *PersistentClient*
- Trade-off: tukar sedikit recall untuk kecepatan

► saat korpus membesar

⑥ Conversational RAG

- Pertanyaan lanjutan (elipsis/kata ganti) → retrieval gagal
- **History-aware rewriting**: tulis ulang jadi mandiri dulu
- Memori **window** (terbaru) + **summary** (lama diringkas)
- Contoh: "Kalau cuti sakit?" → "Berapa hari cuti sakit?"

► percakapan multi-giliran

⑦ Capstone: Sitasi

- Tiap konteks diberi label **[S#]** + halaman/heading
- LLM bubuhkan **[S#]** pada klaim → "Lihat sumber"
- **Verifikasi**: *cited_labels* tandai label di luar rentang
- Ask-My-Documents: PDF → tanya → jawaban terverifikasi

► jawaban bisa ditelusuri

⑧ Deploy (/ask)

- **FastAPI** /ask + **Pydantic** (input cacat → HTTP 422)
- **RagEngine**: muat model **sekali** saat start
- Generator: **NIM** (cloud, tanpa GPU) / **Qwen** (lokal T4)
- Smoke test in-process *TestClient*; runbook = deliverable

► RAG sebagai layanan

Quick-Ref Komponen RAG (8 Notebook)

Lapisan	Library / Model	Tujuan
Embedding	paraphrase-multilingual-MiniLM-L12-v2	Teks → vektor (lintas-bahasa)
Ingest	Docling + HybridChunker	PDF → chunk + metadata sitasi
Rerank	bge-reranker-v2-m3 (cross-encoder)	Urutkan ulang, presisi konteks
Evaluasi	RAGAS + judge NVIDIA NIM	Ukur retrieval & jawaban
Index	FAISS Flat/IVF/HNSW, ChromaDB	Cari cepat + persistensi
Memori	window + summary + rewriting	Percakapan multi-giliran
Sitasi	[S#] + cited_labels	Jawaban terverifikasi
Serving	FastAPI /ask + NIM (Llama-3.3-70B)	Layanan JSON jawaban + sumber

Istilah Kunci

RAG — Retrieval-Augmented Generation: bekali LLM konteks eksternal sebelum menjawab.

Embedding — Teks sebagai vektor; makna mirip → vektor berdekatan (multilingual = lintas-bahasa).

Chunk — Potongan dokumen (unit retrieval); HybridChunker memotong sadar-struktur.

Reranker — Cross-encoder (bge-reranker-v2-m3) yang menilai ulang relevansi kandidat dengan teliti.

RAGAS — Framework evaluasi RAG: Faithfulness, Answer Relevancy, Context Precision, Context Recall.

FAISS — Pencari vektor terdekat yang cepat; Flat (exact) vs IVF/HNSW (perkiraan).

Sitasi [S#] — Label sumber pada klaim; diverifikasi agar tak mengada-ada (*cited_labels*).

NIM — NVIDIA Inference Microservice; LLM cloud (Llama-3.3-70B) andal tanpa GPU lokal.