

Menu Ide Capstone

Bootcamp Navasena. Pilih **satu**, kerjakan sampai tuntas.
Semua project bisa jalan di Google Colab **Tesla T4** (gratis).

Di tahap capstone, kamu membuktikan bahwa skill dari Modul 01 sampai 06 bisa dirangkai menjadi satu produk yang utuh dan jalan. Pilih satu project dari 11 pilihan di bawah, lalu kerjakan sampai memenuhi checklist **Definisi Selesai**-nya.

Ketentuan umum

- **Lingkungan:** Google Colab dengan runtime GPU Tesla T4. Semua project sudah dipastikan cukup di T4; tidak boleh butuh GPU lebih tinggi.
- **Yang dikumpulkan:** (1) notebook .ipynb yang jalan end-to-end di Colab; (2) laporan singkat 3-6 halaman (masalah, data, metode, hasil dan metrik, analisis error, keterbatasan); (3) demo interaktif (Gradio / FastAPI / fungsi di notebook).
- **NVIDIA NIM:** sebagian project meng-offload generasi LLM besar ke NIM (gratis, daftar API key di build.nvidia.com) supaya ringan di T4. Project lain bisa jalan sepenuhnya offline.
- **Main jujur:** pakai metrik yang benar untuk masalahnya, cegah data leakage (pisahkan train/test sebelum transformasi yang belajar dari data), dan jangan pakai dataset gated.
- **Project kesehatan:** bingkai sebagai artefak edukasi, bukan alat medis. Tiap jawaban wajib ada disclaimer.

Ringkasan 11 pilihan

#	Judul	Tingkat	Modul inti	Dataset	ID
1	Audit Adil: deteksi bias sentimen antar kategori produk	Menengah	M06 + M03/M04/M01	PRDECT-ID	Ya
2	Spesialis NL-to-SQL (dengan verifikasi eksekusi)	Menengah	M04 + M06	sql-create-context	–
3	Tanya-Dokter Grounded (RAG kesehatan + disclaimer)	Menengah	M05 + M06/M03	Alodokter QA	Ya
4	IDK-RAG: asisten yang tahu kapan bilang "tidak tahu"	Menengah	M05 + M06/M03/M04	IDK-MRC	Ya
5	Wartawan Mini: spesialis ringkasan dan judul berita	Mahir	M04 + M03/M06	IndoSum	Ya
6	JDIH-Asisten: Ask-My-Regulation hukum ketenagakerjaan	Menengah	M05 + M03/M06/M01	UU 13/2003 (JDIH BPK)	Ya
7	Deteksi fraud pada data tidak seimbang	Menengah	M01	Credit Card Fraud (ULB)	–
8	Pengenal motif batik + Grad-CAM	Menengah	M02 + M06	Indonesian Batik Motifs	Ya
9	Estimator harga mobil bekas Indonesia	Pemula	M01	Used Car Listings ID	Ya
10	Asisten triase kesehatan (spesialis + edge GGUF)	Mahir	M04 + M03/M06	Alodokter QA	Ya
11	Radar emosi ulasan: klasik vs IndoBERT + dashboard (<i>bonus</i>)	Menengah	M03 + M01/M02	PRDECT-ID	Ya

Project 2 dan 7 memakai dataset non-Indonesia (disengaja: keyword SQL memang berbahasa Inggris, dan untuk fraud tidak ada dataset Indonesia dengan kualitas setara). Semua dataset berlisensi publik (CC0, CC-BY, MIT, Apache, atau DbCL).

Detail 11 pilihan project

1. Audit Adil: deteksi bias sentimen antar kategori produk

Menengah

Modul: M06 (inti), M03, M04, M01 · **NIM:** ya (untuk bias-judge)

Tujuan. Audit sebuah classifier sentimen/emosi untuk soal keadilan (fairness): apakah ia memperlakukan tiap kategori produk dan kelompok rating dengan adil, atau ada kelompok yang konsisten dirugikan?

Dataset. PRDECT-ID (review produk Indonesia), lisensi MIT / CC-BY-4.0, sekitar 1,2 MB. github.com/rhiosutoyo/PRDECT-ID-Indonesian-Product-Reviews-Dataset

Yang dibangun. Classifier baseline (TF-IDF dan LogReg), tabel metrik fairness per grup (demographic parity, equalized-odds, disparate impact) dengan uji signifikansi, pengecekan stereotip lewat bias-judge NIM, plus `Model_Card.md` dan checklist etika.

Titik mulai. Pakai ulang fungsi `demographic_parity()` dan `equalized_odds()` dari notebook M06 `03_fairness_and_governance.ipynb`. Bentuk grup audit dari kolom `Category` dan `bin Customer Rating`. Pasang ambang jumlah data minimum untuk kategori yang datanya sedikit.

Definisi Selesai.

- ❑ Classifier baseline jalan dan ada skor keseluruhannya.
- ❑ Tabel metrik fairness per grup (minimal per kategori dan per bin rating).
- ❑ Minimal 300 review dinilai bias-judge untuk stereotip.
- ❑ `Model_Card.md` dan checklist etika dihasilkan.
- ❑ Minimal satu kategori paling bias diidentifikasi plus rekomendasi mitigasi.

Stretch. Tambahkan classifier IndoBERT fine-tune; cek apakah model yang lebih kuat memperbesar atau memperkecil selisih error antar kategori.

2. Spesialis NL-to-SQL: pertanyaan jadi query SQL yang bisa dijalankan

Menengah

Modul: M04 (inti), M06 · **NIM:** opsional (sebagai pembandingan)

Tujuan. Fine-tune model kecil menjadi spesialis text-to-SQL, dan buktikan kebenarannya dengan menjalankan query-nya, bukan sekadar mencocokkan teks.

Dataset. `b-mc2/sql-create-context`, lisensi CC-BY-4.0, 21,8 MB. huggingface.co/datasets/b-mc2/sql-create-context

Yang dibangun. QLoRA fine-tune Qwen3-1.7B, plus skrip verifikasi yang menjalankan SQL prediksi dan SQL gold di SQLite in-memory lalu membandingkan hasilnya tanpa peduli urutan baris. Diuji pada skema bisnis Indonesia buatan sendiri.

Titik mulai. Fork notebook M04 `05_slm_specialist.ipynb`. Pisahkan data sebelum `disubsample`, lalu QLoRA Qwen3-1.7B (nf4, fp16, r=16). Bangun skrip verifikasi: `CREATE TABLE` ke `sqlite3`, jalankan gold dan prediksi, lalu bandingkan.

Definisi Selesai.

- ❑ QLoRA fine-tune selesai dan model bisa menghasilkan SQL.
- ❑ Skrip verifikasi eksekusi membandingkan kesetaraan hasil base vs spesialis di test set.
- ❑ Ada angka akurasi eksekusi base vs spesialis (bukan kecocokan teks).
- ❑ Demo pada skema Indonesia buatan sendiri yang sudah berisi data, dan query-nya mengembalikan angka nyata.

Stretch. Pakai database berisi dari dataset Spider untuk mengukur akurasi pada database terisi, bukan sekadar kesetaraan pada skema kosong.

3. Tanya-Dokter Grounded: RAG info kesehatan dengan sitasi

Menengah

Modul: M05 (inti), M06, M03 · NIM: ya

Penting: artefak edukasi, bukan alat diagnosis. Tiap jawaban wajib ditutup dengan "informasi ini bukan pengganti konsultasi dokter".

Tujuan. Bangun asisten info kesehatan yang menjawab dengan mengutip jawaban dokter asli (bukan berhalusinasi), lalu ukur seberapa besar grounding menekan klaim yang tak berdasar.

Dataset. [agufsamudra/alodokter-qna](#), lisensi Apache-2.0, CSV 2,83 GB (stream dan sampel, jangan load penuh). [huggingface.co/datasets/agufsamudra/alodokter-qna](#)

Yang dibangun. Index FAISS dari sampel tanya-jawab, retrieve dua tahap plus reranker, generasi NIM yang wajib menyitir sumber, guardrail self-check yang memaksa disclaimer, evaluasi RAGAS faithfulness, dan demo FastAPI /ask.

Titik mulai. Anonimkan doctor_name, sampel sekitar 30k. Embed ke FAISS-CPU, ambil top-50, rerank ke top-5. Pakai ulang pola RAG dari M05 nb05/nb07/nb08 dan guardrail dari M06 nb04.

Definisi Selesai.

- ☐ Index FAISS terbentuk dari sampel (bukan load penuh 2,83 GB).
- ☐ Pipeline retrieve, rerank, dan generate jalan, dan jawaban menyertakan sitasi sumber.
- ☐ Guardrail self-check memaksa disclaimer dan memblokir saran dosis.
- ☐ RAGAS faithfulness dibandingkan: grounded vs tanpa RAG pada minimal 25 pertanyaan.
- ☐ Demo FastAPI /ask jalan, dan tiap jawaban memuat disclaimer.

Stretch. Tabel audit guardrail terukur (berapa persen prompt yang minta dosis berhasil diblokir).

4. IDK-RAG: asisten yang tahu kapan bilang "tidak tahu"

Menengah

Modul: M05 (inti), M06, M03, M04 · NIM: ya

Tujuan. Bangun RAG yang menjawab hanya kalau bukti mendukung, dan bilang "tidak tahu" kalau tidak. Ukur kualitas jawaban sekaligus seberapa sering sistem nekat menjawab pertanyaan mustahil.

Dataset. [rifkiaputri/idk-mrc](#) (berisi pertanyaan yang bisa dan tidak bisa dijawab), lisensi CC-BY-4.0, korpus kecil. [huggingface.co/datasets/rifkiaputri/idk-mrc](#)

Yang dibangun. RAG dengan gerbang abstention (berdasar skor reranker), dievaluasi pada split test: EM/F1 untuk yang bisa dijawab plus akurasi abstention untuk yang tidak bisa dijawab, kurva precision vs coverage, dan demo /ask yang balas "tidak tahu" pada pertanyaan luar korpus.

Titik mulai. Angkat pipeline nb07, ganti korpus dengan paragraf IDK-MRC. Tambahkan gerbang abstention (abstain kalau skor reranker tertinggi di bawah ambang), tuning ambang di split VAL.

Definisi Selesai.

- ☐ Pipeline RAG jalan dengan gerbang abstention dua tahap.
- ☐ Dilaporkan di split TEST: EM/F1 (bisa dijawab) plus akurasi abstention dan false-answer rate (tidak bisa dijawab).
- ☐ Kurva precision vs coverage dibuat.
- ☐ Demo mengembalikan "tidak tahu" untuk pertanyaan luar korpus.

Stretch. Bandingkan gerbang ambang reranker dengan cek self-consistency "apakah saya yakin?".

5. Wartawan Mini: spesialis ringkasan dan judul berita

Mahir

Modul: M04 (inti), M03, M06 · **NIM:** ya (sebagai pembeding raksasa)

Tujuan. Fine-tune model kecil menjadi spesialis ringkasan berita Indonesia, lalu buktikan ia bisa menyaingi model raksasa pada satu domain spesifik.

Dataset. IndoSum, lisensi CC-BY-SA-4.0 (data). github.com/kata-ai/indosum

Yang dibangun. QLoRA fine-tune yang menghasilkan ringkasan 2-3 kalimat plus satu judul, dievaluasi ROUGE/BERTScore dan diadu melawan Llama-3.3-70B via NIM, plus demo tempel-artikel dan ekspor GGUF.

Titik mulai. Format tiap artikel jadi instruksi "ringkas lalu beri judul". Pakai ulang kerangka QLoRA dari M04 nb05 dan sel evaluasi dari nb04 (ganti BERTScore ke model multilingual/IndoBERT).

Definisi Selesai.

- ❑ QLoRA fine-tune selesai dan model menghasilkan ringkasan plus judul.
- ❑ ROUGE/BERTScore dilaporkan untuk base vs spesialis vs NIM-70B, dengan uji signifikansi.
- ❑ Demo tempel-artikel jalan dan mengeluarkan ringkasan plus judul.
- ❑ Model di-merge dan diekspor ke GGUF.

Stretch. Coba SmolLM3-3B 4-bit sebagai spesialis lebih besar; bandingkan trade-off ukuran vs kualitas.

6. JDIIH-Asisten: Ask-My-Regulation hukum ketenagakerjaan (sitasi Pasal)

Menengah

Modul: M05 (inti), M03, M06, M01 · **NIM:** ya

Tujuan. Bangun asisten tanya-jawab atas teks UU yang menyitir Pasal persis sumbernya, dan abstain kalau tidak ada Pasal yang relevan.

Dataset. UU 13/2003 Ketenagakerjaan plus klaster Cipta Kerja (PDF resmi JDIIH BPK), domain publik. peraturan.bpk.go.id/Details/43013/uu-no-13-tahun-2003

Yang dibangun. Pipeline Docling yang mem-parse PDF jadi chunk ber-tag Pasal, retrieve plus rerank, jawaban NIM dengan sitasi Pasal wajib, evaluasi RAGAS, dan demo FastAPI /ask.

Titik mulai. Fork nb07, ganti URL-fetch arXiv dengan parsing Docling untuk PDF UU 13/2003. Di HybridChunker, tambahkan field metadata yang menangkap heading "Pasal N" terdekat lewat regex. Kerjakan dulu satu UU saja.

Definisi Selesai.

- ❑ Docling mem-parse PDF menjadi chunk yang ber-tag nomor Pasal.
- ❑ Pipeline retrieve, rerank, dan generate jalan, dan jawaban menyebut Pasal sumbernya.
- ❑ Sistem abstain kalau tidak ada Pasal relevan.
- ❑ RAGAS dijalankan pada minimal 30 pertanyaan ketenagakerjaan.
- ❑ Demo FastAPI /ask jalan.

Stretch. Tambahkan amandemen Cipta Kerja (UU 6/2023) dan lacak Pasal yang masih berlaku vs yang sudah dicabut.

7. Deteksi transaksi fraud pada data tidak seimbang

Menengah

Modul: M01 · **NIM:** tidak (sepenuhnya offline)

Tujuan. Deteksi fraud pada data yang sangat tidak seimbang (hanya 0,172% fraud), dengan teknik dan metrik yang benar. Pahami kenapa "akurasi" menyesatkan di sini.

Dataset. Credit Card Fraud Detection (ULB), lisensi DbCL v1.0, sekitar 144 MB. kaggle.com/datasets/mlg-ulb/creditcardfraud

Yang dibangun. Pipeline lengkap: EDA yang membuktikan jebakan akurasi, eksperimen resampling, perbandingan model dengan PR-AUC/recall/precision, threshold tuning berbasis biaya, dan demo skoring satu transaksi.

Titik mulai. Load data, buat EDA jebakan-akurasi (model dummy "selalu bukan-fraud" mencapai akurasi 99,83% tapi nol fraud tertangkap). Rangkai imblearn. Pipeline supaya resampling hanya terjadi di dalam fold training.

Definisi Selesai.

- ❑ EDA membuktikan jebakan akurasi secara eksplisit.
- ❑ Minimal 3 model dibandingkan lewat PR-AUC/recall/precision plus confusion matrix.
- ❑ Resampling hanya terjadi di dalam fold training (tidak ada leakage).
- ❑ Threshold dipilih berbasis fungsi biaya, bukan default 0,5.
- ❑ Kurva PR plus rekomendasi operasional ada di laporan.

Stretch. Tambahkan kalibrasi probabilitas dan sapuan cost-curve untuk menunjukkan pergeseran titik operasi optimal.

8. Pengenal motif batik Nusantara dengan Grad-CAM

Menengah

Modul: M02 (inti), M06 · **NIM:** tidak

Tujuan. Bangun classifier motif batik yang tidak cuma menebak nama motif, tapi juga menunjukkan bagian kain mana yang jadi dasar keputusannya lewat Grad-CAM.

Dataset. Indonesian Batik Motifs (Corak App), lisensi CC0, sekitar 156 MB. kaggle.com/datasets/alfanme/indonesian-batik-motifs-corak-app

Yang dibangun. Training transfer learning ResNet50, metrik per kelas, overlay heatmap Grad-CAM, dan demo Gradio yang menyebut nama motif sambil menampilkan heatmap.

Titik mulai. Mulai dari M02 nb03, ganti loader CIFAR-10 dengan `image_dataset_from_directory` atas folder batik. Bangun ResNet50 dengan backbone beku, latih 10-15 epoch, lalu tambahkan Grad-CAM.

Definisi Selesai.

- ResNet50 transfer learning terlatih, ada precision/recall per kelas plus confusion matrix.
- Grad-CAM menghasilkan overlay heatmap yang masuk akal di gambar uji.
- Demo Gradio jalan: input gambar, output nama motif plus heatmap.
- Laporan menyebut motif yang paling sering tertukar.

Stretch. Bandingkan dua backbone (ResNet50 vs MobileNetV2), atau benchmark latency ONNX/TensorRT di T4.

9. Estimator harga mobil bekas Indonesia

Pemula

Modul: M01 · **NIM:** tidak · jalur masuk paling ringan

Tujuan. Prediksi harga mobil bekas dari listing nyata, lalu jelaskan fitur mana yang paling menentukan harga. Output akhirnya alat "cek harga wajar" yang langsung berguna.

Dataset. Used Car Listings in Indonesia, lisensi CC0, sekitar 25 KB. kaggle.com/datasets/indraputra21/used-car-listings-in-indonesia

Yang dibangun. Pipeline regresi: cleaning, feature engineering, perbandingan beberapa model dengan cross-validation, analisis fitur penting, dan fungsi `estimasi_harga(spek)` yang interaktif.

Titik mulai. Parse harga dan kilometer jadi numerik, hitung umur mobil, encode kolom kategori. Latih Linear/Ridge/RandomForest/XGBoost dalam satu loop dengan `cross_val_score` 5-fold.

Definisi Selesai.

- Data dibersihkan dan ada feature engineering (minimal umur mobil plus encoding).
- Minimal 3 model dibandingkan dengan RMSE/MAE/R2 plus cross-validation.
- Feature importance plus analisis residual per segmen harga ada.
- Fungsi `estimasi_harga(spek)` jalan interaktif dan menampilkan rentang prediksi.

Stretch. Jalankan ulang RandomForest di cuML untuk menunjukkan speedup di T4.

10. Asisten triase kesehatan: spesialis tanya-jawab plus edge GGUF

Mahir

Modul: M04 (inti), M03, M06 · **NIM:** ya (sebagai judge)

Penting: artefak edukasi, bukan alat triase sungguhan. Output wajib ditutup dengan disclaimer dan blok "kapan harus ke dokter".

Tujuan. Fine-tune spesialis yang menjawab pertanyaan kesehatan awam dengan struktur ala dokter, tapi sadar batas: selalu menutup dengan disclaimer dan triase red-flag. Lalu deploy offline lewat Ollama GGUF.

Dataset. [agufsamudra/alodokter-qna](https://huggingface.co/datasets/agufsamudra/alodokter-qna), lisensi Apache-2.0. huggingface.co/datasets/agufsamudra/alodokter-qna

Yang dibangun. QLoRA fine-tune dengan kerangka output yang selalu menambahkan disclaimer plus red-flag, perbandingan base vs spesialis, LLM-judge keamanan via NIM, ekspor GGUF, dan demo Ollama.

Titik mulai. Anonimkan `doctor_name`, subsample sekitar 10k. Bungkus tiap pasangan dalam template yang output-nya selalu memuat disclaimer plus blok red-flag, supaya aspek keamanan ikut dilatih.

Definisi Selesai.

- QLoRA fine-tune selesai dengan kerangka disclaimer plus red-flag yang konsisten muncul.
- Perbandingan base vs spesialis ada (contoh sebelum dan sesudah).
- LLM-judge menilai keamanan dan faktualitas.
- Model diekspor ke GGUF Q4_K_M dan jalan di Ollama.
- Laporan menganalisis kasus di mana model tidak boleh menjawab, dan dibingkai tegas sebagai edukasi.

Stretch. Tambahkan rail NeMo Guardrails self-check dan ukur berapa output tak aman yang tertangkap.

11. Radar emosi ulasan: klasik vs IndoBERT plus dashboard (bonus)

Menengah

Modul: M03 (inti), M01, M02 · **NIM:** tidak (hanya di stretch)

Tujuan. Klasifikasi review ke 5 emosi, adu baseline klasik melawan IndoBERT, lalu kemas jadi dashboard yang membantu penjual UMKM membaca suara pelanggan, lebih dari sekadar rating bintang.

Dataset. PRDECT-ID, lisensi CC-BY-4.0, sekitar 1,26 MB. data.mendeley.com/datasets/574v66hf2v/1

Yang dibangun. Baseline TF-IDF dan SVM, IndoBERT fine-tune, analisis error per emosi, dan dashboard Gradio yang memetakan emosi per kategori serta menandai review marah/sedih sebagai komplain prioritas.

Titik mulai. Bangun baseline klasik dulu (TfidfVectorizer dan LinearSVC), baru fine-tune indobenchmark/indobert-base-p1 dengan num_labels=5. Catatan: pergantian head ke AutoModelForSequenceClassification tidak diajarkan di kelas, jadi kamu perlu baca dokumentasinya sendiri (bagian dari tantangan).

Definisi Selesai.

- Baseline TF-IDF dan SVM jalan, ada macro-F1 plus confusion matrix.
- IndoBERT fine-tune jalan, ada macro-F1 plus confusion matrix per emosi.
- Perbandingan klasik vs transformer dianalisis (bukan cuma angka, tapi di mana masing-masing unggul).
- Dashboard Gradio jalan: memetakan emosi per kategori dan menandai komplain prioritas.

Stretch. Tambahkan perbandingan dengan klasifikasi zero-shot NIM-LLM, untuk melihat di mana model kecil yang terspesialisasi menang.

Rubrik penilaian

Aspek	Bobot	Yang dinilai
Fungsionalitas end-to-end	30%	Notebook jalan dari data sampai demo, tanpa error fatal.
Ketepatan metrik dan evaluasi	25%	Metrik yang dipakai benar untuk masalahnya (lihat Definisi Selesai tiap project).
Trustworthy AI dan keamanan	15%	Disclaimer, abstention, sitasi, audit bias, atau guardrail sesuai konteks.
Kualitas laporan dan komunikasi	20%	Analisis error jujur, keterbatasan diakui, ada insight, bukan cuma angka.
Demo dan reproduktibilitas	10%	Demo jalan, dan orang lain bisa menjalankan ulang di Colab T4.

Bootcamp NCA-GENL (Navasena) · Menu Ide Capstone · Semua project diverifikasi cukup di Google Colab Tesla T4 · Pilih yang paling bikin kamu penasaran.